

Lista 1 — Prova 1

Bases 3 — Estatística · Análise Exploratória e Probabilidade

Nome: _____ Matrícula: _____

Entrega: manuscrita, até 30/10/2026 · 30 questões · 0,5 ponto cada · 15 pontos

Você pode usar Python (Colab) como calculadora, mas as respostas devem ser **escritas à mão**. Nas questões abertas, mostre o raciocínio; nas fechadas, marque a letra **e justifique**.

Matriz de cobertura

Conferência do professor — cada seção dos Capítulos 1 e 2 é tocada por ao menos uma questão (exercícios integrativos aparecem em mais de uma linha).

Seção	Questões
1.1 Elementos de Dados Estruturados	1, 2
1.2 Dados Retangulares	1, 2
1.3 Estimativas de Localização	3, 4, 15
1.4 Estimativas de Variabilidade	5, 6, 15
1.5 Explorando a Distribuição dos Dados	5, 7, 8, 15
1.6 Dados Binários e Categóricos	9, 10
1.7 Correlação	11, 12
1.8 Duas ou Mais Variáveis	13, 14
2.1 O que é Probabilidade	16
2.2 Regras de Probabilidade	17, 18
2.3 Probabilidade Condicional e Bayes	19, 20
2.4 Contagem: Permutação e Combinação	21, 22, 30
2.5 Distribuição Binomial	23, 24, 30
2.6 Distribuição Hipergeométrica	23, 25
2.7 Distribuição Normal	26, 27, 28, 29
2.8 Distribuições de Cauda Longa	28

Bloco 1 — Análise Exploratória de Dados

1. (0,5) Um sistema de matrícula universitária registra, entre outros, os campos abaixo para cada aluno:

Campo	Exemplo de valor
Matrícula	202301234

Campo	Exemplo de valor
Situação	Ativo
Conceito final do período	B
Créditos cursados no período	12
CR (coeficiente de rendimento)	7,8

Qual alternativa classifica corretamente **todos** os cinco campos, na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário)?

- (a) Matrícula: numérico discreto; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (b) Matrícula: categórico nominal; Situação: ordinal; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (c) Matrícula: categórico nominal; Situação: binário; Conceito: categórico nominal; Créditos: numérico discreto; CR: numérico contínuo.
- (d) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico contínuo; CR: numérico contínuo.
- (e) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.

Resolução

Resposta: **(e)**. Matrícula é um identificador — apesar do formato numérico, somar ou tirar a média de duas matrículas não significa nada, então é categórico nominal (o mesmo caso do CEP visto na seção 1.1). Situação (Ativo/Trancado) tem exatamente duas categorias, sem soma nem distância entre elas: binário. Conceito (A a E) tem ordem — B é melhor que D —, mas não uma distância numérica definida entre as letras: ordinal. Créditos cursados é uma contagem, só assume valores inteiros: numérico discreto. CR é uma média com casas decimais, que pode assumir qualquer valor num intervalo: numérico contínuo.

Distratores: (a) trata a Matrícula como numérico discreto — o erro clássico de confundir um identificador com uma quantidade; (b) atribui ordem a Situação, que não tem nenhuma — “Ativo” não é “mais” nem “menos” que “Trancado”; (c) trata Conceito como nominal, perdendo a informação de ordem entre as notas; (d) trata Créditos cursados como numérico contínuo, ignorando que é uma contagem — nunca assume uma fração de crédito.

2. **(0,5)** Um cadastro de produtos de um e-commerce tem as seguintes variáveis: **SKU** (código do produto, ex.: **ELX-0234**), **Categoria** (Eletrônicos, Roupas, Alimentos, Livros), **Avaliação média dos clientes** (de 1 a 5 estrelas, em passos inteiros), **Quantidade em estoque** (unidades inteiras), **Preço unitário** (R\$, com centavos) e **Em promoção** (Sim/Não). Classifique cada uma das seis variáveis na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário), justificando cada resposta em uma frase.

Resolução

- **SKU**: categórico **nominal** — é um identificador; o formato alfanumérico não implica ordem nem distância entre dois códigos.
- **Categoria**: categórico **nominal** — não há ordem natural entre Eletrônicos, Roupas, Alimentos e Livros.
- **Avaliação média dos clientes**: categórico **ordinal** — há ordem (5 estrelas é melhor que 1), mas a distância entre “4” e “5” não é necessariamente igual à distância entre “1” e “2”.
- **Quantidade em estoque**: numérico **discreto** — é uma contagem de unidades, só assume valores inteiros.
- **Preço unitário**: numérico **contínuo** — pode assumir qualquer valor dentro de um intervalo.
- **Em promoção**: categórico **binário** — exatamente duas categorias, sem soma nem distância entre elas.

Cada produto é um registro (uma linha da tabela de cadastro); as seis variáveis acima são as colunas — as *features* que descrevem cada registro, na terminologia da seção 1.2.

3. (0,5) Um sistema de suporte técnico registrou o tempo de atendimento (em minutos) de 10 chamados consecutivos: 4, 5, 5, 6, 6, 7, 7, 8, 9 e 50 (este último passou por escalonamento e ficou muito tempo em fila). Calcule a média, a mediana e a média aparada de 10% desse conjunto. Qual dessas três medidas descreve melhor o tempo “típico” de atendimento, e por quê?

Resolução

```
média = 10,70 min  
mediana = 6,50 min  
média aparada (10%) = 6,62 min
```

A média é 10,70 minutos — bem acima da maioria dos chamados —, porque o único chamado escalonado (50 minutos) puxa a soma para cima. A mediana, 6,50 minutos, e a média aparada de 10%, 6,62 minutos, ficam muito mais próximas do que a maioria dos chamados realmente levou: a mediana porque só enxerga o valor central, e a aparada porque descarta 1 observação de cada ponta antes de calcular a média (10% de 10 chamados = 1). A medida mais representativa do tempo “típico” é a mediana (ou a aparada) — a média, aqui, é distorcida por um único outlier, o mesmo padrão de robustez discutido nas seções 1.3 a 1.5.

4. (0,5) Uma rede de lojas tem três filiais. A tabela abaixo mostra o valor médio de venda por cliente e o número de transações de cada filial em um mês.

Filial	Valor médio (R\$)	Transações
Centro	40	400
Norte	90	50
Sul	100	50

Qual das alternativas está correta?

- (a) A média simples dos três valores médios (R\$ 76,67) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois trata as três filiais com o mesmo peso.
- (b) A média ponderada pelo número de transações (R\$ 51,00) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois dá mais peso à filial com mais transações.
- (c) A média ponderada será sempre maior que a média simples quando os pesos são diferentes entre os grupos.
- (d) Como a filial Centro tem 400 transações — muito mais que as outras —, sua média de R\$ 40 deve ser tratada como um outlier e descartada do cálculo.
- (e) A média ponderada e a média simples medem exatamente a mesma grandeza e, por isso, são sempre iguais.

Resolução

```
média simples = 76,67  
média ponderada = 51,00
```

A média simples é 76,67 e a média ponderada é 51,00. Resposta: **(b)**. Distratores: (a) trata as filiais como se tivessem o mesmo tamanho, ignorando que Centro sozinho responde por 400 das 500 transações — o mesmo erro que compararia a taxa de homicídios simples dos estados com a ponderada sem levar a população em conta; (c) é falso neste próprio exemplo: a ponderada (51,00) é **menor** que a simples (76,67), porque a maior

filial tem a menor média — a direção depende dos dados, não é uma lei geral; (d) confunde “grupo grande” com “outlier”: outlier é um valor atípico dentro de uma distribuição, não uma categoria numerosa; (e) é o erro oposto de (c): supor que as duas médias são sempre iguais ignora que elas respondem perguntas diferentes, e só coincidem quando os pesos são iguais.

5. (0,5) Um time de QA registrou o número de erros encontrados por dia, ao longo de 9 dias de testes de um novo sistema: 2, 3, 3, 4, 5, 5, 6, 7, 9. Calcule a variância amostral, o desvio-padrão amostral e o IQR ($Q_3 - Q_1$) desse conjunto. Em seguida, escreva uma frase interpretando o IQR no contexto do problema.

Resolução

```
média = 4,89
variância amostral = 4,86
desvio-padrão amostral = 2,20
Q1 = 3,0    Q3 = 6,0
IQR = 3,0
```

A variância amostral é 4,86 e o desvio-padrão amostral é 2,20 erros/dia. O IQR é 3,0 (de $Q_1 = 3,0$ a $Q_3 = 6,0$). Interpretação: os 50% centrais dos 9 dias de teste tiveram entre 3,0 e 6,0 erros por dia — uma faixa bem mais estreita que a variação total (de 2 a 9), o que mostra que a maioria dos dias ficou concentrada num intervalo pequeno, com poucos dias puxando as pontas.

6. (0,5) As notas de uma avaliação de 5 alunos são: 6, 7, 7, 8, 12. Qual das alternativas apresenta corretamente o desvio-padrão amostral, a variância amostral e a amplitude total (máximo – mínimo) desse conjunto (arredondados a 2 casas quando necessário)?

- (a) desvio-padrão = 5,50; variância = 2,35; amplitude = 6
- (b) desvio-padrão = 2,35; variância = 5,50; amplitude = 6
- (c) desvio-padrão = 2,10; variância = 4,40; amplitude = 6
- (d) desvio-padrão = 2,35; variância = 5,50; amplitude = 12
- (e) desvio-padrão = 4,69; variância = 22,00; amplitude = 6

Resolução

```
variância amostral = 5,50
desvio-padrão amostral = 2,35
amplitude = 6
```

Variância = 5,50; desvio-padrão = 2,35; amplitude = 6. Resposta: **(b)**. Distratores: (a) inverte desvio-padrão e variância — o desvio-padrão é sempre a **raiz** da variância; (c) usa n no denominador em vez de $n - 1$ (divide a soma dos quadrados dos desvios por 5 em vez de 4) — o erro clássico de usar a fórmula populacional numa amostra; (d) confunde amplitude com o valor máximo, esquecendo de subtrair o mínimo; (e) esquece de dividir a soma dos quadrados dos desvios (22) por $n - 1$, reportando a soma bruta como se fosse a variância, e tira a raiz dessa soma bruta para chegar a um “desvio-padrão” que não é.

7. (0,5) As idades (em anos) de 9 clientes cadastrados em uma loja, já em ordem crescente, são: 18, 20, 22, 25, 27, 30, 33, 35, 40. Qual das alternativas apresenta corretamente o primeiro quartil (Q_1), o terceiro quartil (Q_3) e o IQR desse conjunto?

- (a) $Q_1 = 20$; $Q_3 = 35$; IQR = 15
- (b) $Q_1 = 22$; $Q_3 = 33$; IQR = 11
- (c) $Q_1 = 22$; $Q_3 = 33$; IQR = 55
- (d) $Q_1 = 25$; $Q_3 = 30$; IQR = 5

(e) $Q_1 = 18$; $Q_3 = 40$; $IQR = 22$

Resolução

```
Q1 = 22
Q3 = 33
IQR = 11
```

$Q_1 = 22$; $Q_3 = 33$; $IQR = 11$. Resposta: **(b)**. Distratores: (a) usa as posições vizinhas erradas (a 2ª e a 8ª observações, em vez da 3ª e da 7ª); (c) soma Q_3 e Q_1 em vez de subtrair — o IQR é sempre uma diferença, nunca uma soma; (d) confunde quartil com os valores logo ao lado da mediana (4ª e 6ª observações); (e) confunde quartil com os extremos do conjunto (mínimo e máximo), que marcariam a amplitude total, não a amplitude interquartil.

8. (0,5) O resumo de cinco números de um conjunto de dados é: mínimo = 6, $Q_1 = 20$, mediana = 22, $Q_3 = 30$, máximo = 68. (a) Calcule o IQR e os limites do bigode pela regra de $1,5 \times IQR$. (b) O mínimo e o máximo são outliers? (c) Descreva a forma da distribuição — a posição da mediana dentro da caixa e a assimetria provável.

Resolução

```
IQR = 10,0
limite inferior = 5,0
limite superior = 45,0
mínimo é outlier? não
máximo é outlier? sim
```

$IQR = 10,0$. Limite inferior do bigode = 5,0; limite superior = 45,0. O mínimo (6) está **acima** do limite inferior (5) — não é outlier, e o bigode inferior se estende até ele. O máximo (68) está muito **acima** do limite superior (45) — é um outlier, desenhado como ponto isolado; o bigode superior real vai só até o maior valor não-outlier (≤ 45). Quanto à forma: a mediana (22) está a apenas 2 unidades de Q_1 (20) e a 8 unidades de Q_3 (30) — mais perto do lado de baixo da caixa —, e o outlier fica acima. Os dois sinais apontam na mesma direção: cauda (e mediana deslocada) para a direita, ou seja, **assimetria positiva**.

9. (0,5) Um sistema de e-commerce registra o método de pagamento de 200 pedidos: Cartão de crédito (120), Boleto (50), Pix (30). Qual das alternativas está correta?

- (a) A moda dessa variável é “Cartão de crédito”, pois é o método mais frequente (60% dos pedidos).
- (b) A média dos três valores (120, 50, 30) representa o método de pagamento típico dos pedidos.
- (c) Como “Pix” tem a menor contagem, ele deve ser excluído da análise por ser um outlier.
- (d) Cada método de pagamento tem probabilidade de $1/3$ (33,3%), pois há três categorias possíveis.
- (e) A mediana dessa variável categórica é “Boleto”, por ter contagem intermediária.

Resolução

```
Cartão de crédito: 60,0%
Boleto: 25,0%
Pix: 15,0%
moda = Cartão de crédito
```

As proporções são 60%, 25% e 15%, calculadas acima; a moda é Cartão de crédito. Resposta: **(a)**. Distratores: (b) tenta calcular a média de uma variável nominal — não há soma nem ordem entre métodos de pagamento, a operação não significa nada; (c) confunde “categoria rara” com “outlier” — outlier é um valor atipicamente

distante da distribuição de uma variável numérica, não a categoria menos frequente de uma nominal (a mesma armadilha do exercício da causa “Segurança” nos atrasos de voo, seção 1.6); (d) confunde “número de categorias” com “distribuição uniforme” — três categorias não implicam três probabilidades iguais; a distribuição real é bem desigual (60/25/15); (e) tenta calcular uma mediana de categorias nominais, que não têm ordem entre si — a ordem em que as categorias aparecem na tabela é arbitrária.

10. (0,5) Uma operadora de telecomunicações registra os motivos de reclamação de 250 clientes em um mês, com o custo médio de resolução de cada tipo:

Motivo	Frequência	Custo de resolução (R\$)
Cobrança indevida	120	50
Queda de sinal	80	30
Atendimento	40	20
Outro	10	100

Calcule a proporção de cada motivo, identifique a moda, e calcule o valor esperado do custo de resolução por reclamação. Por que o motivo “Outro”, apesar de ter o maior custo unitário, contribui pouco para o valor esperado total?

Resolução

Cobrança indevida: proporção = 48,0% contribuição = R\$ 24,00
 Queda de sinal: proporção = 32,0% contribuição = R\$ 9,60
 Atendimento: proporção = 16,0% contribuição = R\$ 3,20
 Outro: proporção = 4,0% contribuição = R\$ 4,00
 valor esperado total = R\$ 40,80

As proporções (na ordem da tabela) são 48,0%, 32,0%, 16,0% e 4,0%. A moda é “Cobrança indevida”, a categoria mais frequente. O valor esperado do custo de resolução por reclamação é R\$ 40,80. “Outro” custa o dobro do mais caro entre os demais (R\$ 100 contra R\$ 50), mas contribui apenas R\$ 4,00 para o valor esperado, contra R\$ 24,00 de “Cobrança indevida” — porque a contribuição de cada motivo é proporção vezes custo, e uma proporção pequena (4%) reduz mesmo um custo unitário grande. O valor esperado pondera custo por probabilidade; não olha o custo isolado.

11. (0,5) Um estudo com trabalhadores encontra uma correlação de Pearson $r = -0,82$ entre “horas de sono por noite” e “número de erros cometidos em uma tarefa de digitação”. Qual das alternativas está correta?

- (a) Como r é negativo e próximo de -1 , há uma associação linear forte: mais horas de sono tendem a estar associadas a menos erros — mas isso, sozinho, não prova que dormir mais causa a redução de erros.
- (b) $r = -0,82$ significa que dormir mais horas causa, necessariamente, uma redução no número de erros.
- (c) Como r é negativo, não existe associação alguma entre as duas variáveis.
- (d) $r = -0,82$ indica uma associação fraca, pois está distante do valor mínimo possível, -2 .
- (e) Se as horas de sono fossem medidas em minutos em vez de horas, o valor de r mudaria substancialmente.

Resolução

Resposta: **(a)**. O sinal negativo indica que as duas variáveis se movem em direções opostas — mais sono, menos erros —, e a magnitude (0,82, próxima de 1) indica associação linear forte. Mesmo assim, correlação não é prova de causalidade: uma terceira variável (por exemplo, o nível geral de estresse ou a carga de trabalho) poderia afetar sono e desempenho ao mesmo tempo. Distratores: (b) comete o erro clássico de tratar correlação como causa; (c) confunde sinal negativo com ausência de associação — um r negativo indica uma

direção de associação, não a falta dela (é o valor 0, não o sinal, que indicaria ausência de relação linear); (d) supõe que r pode variar além do intervalo $[-1, 1]$, o que é matematicamente impossível — o denominador da fórmula de Pearson garante que $|r| \leq 1$; (e) ignora que r é adimensional: converter horas em minutos é uma transformação linear, e a correlação de Pearson é invariante a mudanças de escala e unidade.

12. (0,5) Uma pesquisadora relaciona horas semanais de estudo (x) e nota em uma avaliação, de 0 a 100 (y), de 6 estudantes: (2, 50), (4, 55), (6, 65), (8, 70), (10, 80), (12, 100). Calcule o coeficiente de correlação de Pearson entre x e y (mostre as somas intermediárias) e interprete o valor obtido. Essa correlação, por si só, permite concluir que estudar mais **causa** uma nota maior? Justifique.

Resolução

```
média de x = 7,0    média de y = 70,0
soma dos produtos cruzados = 330,0
soma dos desvios2 de x = 70,0    soma dos desvios2 de y = 1.650,0
r = 0,971
```

$r = 0,971$. É uma correlação positiva e muito forte: horas de estudo maiores estão associadas a notas mais altas, de forma quase perfeitamente linear nesta amostra. Mas r mede apenas associação, não causa: um terceiro fator — motivação do estudante, conhecimento prévio da matéria, tempo disponível fora do trabalho — pode influenciar tanto as horas de estudo quanto o desempenho na prova, gerando essa associação sem que estudar “cause” a nota diretamente. Além disso, com apenas 6 pontos, um único par atípico teria grande influência sobre r — a segunda armadilha da correlação, sensibilidade a outliers.

13. (0,5) A tabela abaixo mostra a situação de pagamento de empréstimos de duas notas de risco:

Nota	Em dia	Inadimplente	Total
A	170	30	200
B	35	15	50

Qual das alternativas está correta?

- (a) A nota A é mais arriscada que a nota B, pois tem mais empréstimos inadimplentes em número absoluto (30 contra 15).
- (b) A taxa de inadimplência da nota B (30%) é maior que a da nota A (15%); logo, B é a nota mais arriscada, mesmo tendo bem menos empréstimos no total.
- (c) Como a nota A tem quatro vezes mais empréstimos que a nota B, sua taxa de inadimplência também deveria ser proporcionalmente maior.
- (d) É impossível comparar o risco das duas notas, porque elas têm números totais de empréstimos muito diferentes.
- (e) Somando as duas notas, há 45 empréstimos inadimplentes em 250 no total (18%); esse número agregado já mostra que as duas notas têm risco parecido.

Resolução

```
taxa de inadimplência A = 15,0%
taxa de inadimplência B = 30,0%
```

Taxa de A = 15,0%; taxa de B = 30,0%. Resposta: **(b)**. Distratores: (a) compara contagens absolutas entre grupos de tamanhos muito diferentes (200 contra 50) — o mesmo erro clássico da seção 1.8: um grupo maior naturalmente acumula mais de tudo, inclusive mais casos de qualquer tipo, sem que isso diga nada sobre a taxa; (c) inverte a lógica — o tamanho do grupo não determina a taxa de risco, são grandezas independentes;

(d) é o oposto do que a proporção resolve: normalizar pelo total de cada linha é exatamente a ferramenta para comparar grupos de tamanhos diferentes; (e) mistura as duas notas num único número (18%) que não é a taxa de nenhuma delas — a agregação apaga a diferença real entre 15% e 30%, o mesmo tipo de armadilha que a próxima questão explora de forma ainda mais extrema.

14. (0,5) Duas técnicas de recuperação de servidores após falha, P e Q, foram testadas em incidentes de dois tipos — leves e graves. A tabela abaixo mostra quantos incidentes foram recuperados dentro do prazo de SLA (sucesso) em cada combinação de técnica e tipo:

Tipo de incidente	Técnica	Sucessos	Total de incidentes
Leve	P	180	200
Leve	Q	47	50
Grave	P	10	50
Grave	Q	36	150

- (a) Calcule a taxa de sucesso de P e de Q em cada tipo de incidente. (b) Calcule a taxa de sucesso agregada (somando os dois tipos) de P e de Q. (c) Há uma inversão entre o resultado por tipo e o resultado agregado? Qual variável escondida (confundidora) provoca essa inversão, e por quê?

Resolução

Leve — P: 90,0% Q: 94,0%
 Grave — P: 20,0% Q: 24,0%
 Agregado — P: 76,0% (190/250) Q: 41,5% (83/200)

Por tipo, Q vence em ambos: leve 94,0% contra 90,0%, grave 24,0% contra 20,0%. Mas no agregado, P vence disparado: 76,0% contra 41,5%. Há inversão — é o **paradoxo de Simpson**. A variável escondida é o tipo de incidente: P foi testada majoritariamente em incidentes leves (200 de 250 testes, 80% — o tipo com taxa de sucesso mais alta para as duas técnicas), enquanto Q foi testada majoritariamente em incidentes graves (150 de 200, 75% — o tipo mais difícil para as duas). O agregado de P herda o peso do tipo fácil; o de Q herda o peso do tipo difícil — e essa diferença de composição, não uma superioridade real da técnica P, é o que decide o total. Comparar apenas o agregado, sem checar como os testes foram distribuídos entre os dois tipos, levaria a escolher a técnica pior nos dois cenários que realmente importam.

15. (0,5) As notas de 7 alunos em uma prova foram: 60, 62, 65, 68, 70, 72 e 5 (o último aluno entregou a prova em branco, exceto por uma questão). Qual das alternativas está correta?

- (a) A média (57,43) é maior que a mediana (65), porque o outlier baixo eleva a média.
 (b) A média (57,43) é menor que a mediana (65), porque a nota 5 é um outlier baixo que puxa a média para baixo, enquanto a mediana permanece próxima do grosso das notas.
 (c) O desvio-padrão é uma medida mais robusta que a mediana diante desse outlier, pois usa todas as observações no cálculo.
 (d) Remover o outlier não afetaria a mediana, mas afetaria bastante a média; por isso, a mediana deve sempre substituir a média em qualquer conjunto de dados.
 (e) Como a média é menor que a mediana, a distribuição dessas notas é assimétrica à direita.

Resolução

média = 57,43
 mediana = 65,00

Média = 57,43; mediana = 65,00. Resposta: **(b)**. Distratores: (a) inverte o sentido da comparação (a média não é maior, é menor) e inverte o efeito do outlier (um outlier baixo puxa a média para **baixo**, não para cima); (c) é o oposto da verdade — o desvio-padrão eleva os desvios ao quadrado, o que o torna **ainda mais** sensível a extremos que a própria média; usar “todas as observações” não é sinônimo de robustez, é exatamente a razão da fragilidade; (d) generaliza demais: a mediana é preferível quando há outliers ou cauda longa plausível, mas isso não significa que ela deva “sempre” substituir a média — para dados simétricos e sem outliers, a média é tão boa quanto, e mais eficiente estatisticamente; (e) inverte a regra da seção 1.5: média menor que a mediana é o sinal de assimetria à **esquerda** (negativa), não à direita — a regra é “assimetria positiva → cauda à direita → média maior que a mediana”, e aqui o sinal está trocado.

Bloco 2 — Probabilidade e Distribuições

16. **(0,5)** Numa reunião de planejamento, uma equipe de dados afirma: “a probabilidade de o próximo deploy quebrar a produção é 0,15”. Sobre essa afirmação e sobre o conceito de probabilidade, qual alternativa está correta?

- (a) A afirmação não faz sentido: como um deploy específico ou quebra ou não quebra a produção, probabilidade só se aplica a experimentos que podem ser repetidos infinitas vezes nas mesmas condições.
- (b) O número 0,15 é mais naturalmente lido como um grau de crença (visão bayesiana), atualizável quando chegar nova evidência; a leitura frequentista teria de reinterpretá-lo como a fração de deploys “parecidos com este”, no histórico, que quebraram a produção.
- (c) Na visão frequentista, 0,15 é um grau de crença subjetivo do time; na visão bayesiana, é uma frequência de longo prazo.
- (d) Como há apenas dois resultados possíveis (quebra ou não quebra), cada um tem probabilidade 0,5 — logo o valor 0,15 está necessariamente errado.
- (e) A afirmação é frequentista pelo simples fato de atribuir um número entre 0 e 1 ao evento.

Resolução

Resposta: **(b)**. Um deploy específico é um evento que acontece uma única vez — não há uma sequência de “próximos deploys idênticos” para contar. A visão **bayesiana** (grau de crença) atribui probabilidade diretamente a um evento único e a atualiza com nova evidência, então é a leitura mais natural aqui; a visão **frequentista** só dá sentido ao número reinterpretando o evento como repetível (“entre deploys parecidos com este, que fração quebrou?”). Distratores: (a) nega que exista qualquer leitura válida para eventos únicos — mas é exatamente para eles que a interpretação bayesiana serve (o mesmo caso do “70% de chance de chuva amanhã” da seção 2.1); (c) inverte as duas definições — frequentista é a frequência de longo prazo, bayesiana é o grau de crença, não o contrário; (d) comete a falácia de supor que “dois resultados possíveis” implica “resultados igualmente prováveis” — quebrar e não quebrar não precisam ter a mesma chance; (e) confunde o formato do número com sua interpretação — as duas visões usam números em $[0, 1]$, então isso não distingue uma da outra.

17. **(0,5)** Numa loja virtual, 40% dos clientes usam algum cupom de desconto ($P(C) = 0,40$), 25% são clientes novos ($P(N) = 0,25$) e 10% usam cupom e são novos ($P(C \cap N) = 0,10$). (a) Qual a probabilidade de um cliente usar cupom **ou** ser novo? (b) Qual a probabilidade de um cliente **não** usar cupom? (c) Os eventos “usar cupom” e “ser cliente novo” são independentes? Justifique pela definição.

Resolução

$$\begin{aligned} P(\text{cupom ou novo}) &= 0,55 \\ P(\text{não usar cupom}) &= 0,60 \\ P(C) \cdot P(N) &= 0,10 \quad P(C \text{ e } N) = 0,10 \end{aligned}$$

- (a) Os dois eventos podem ocorrer juntos (um cliente novo pode usar cupom), então a regra da adição precisa subtrair a interseção: $P(C \cup N) = P(C) + P(N) - P(C \cap N) = 0,55$. (b) Pelo complementar, $P(\bar{C}) = 1 - P(C) = 0,60$. (c) A definição de independência exige $P(C \cap N) = P(C) \cdot P(N)$. Aqui $P(C) \cdot P(N) = 0,10$, exatamente igual ao $P(C \cap N) = 0,10$ informado — então os dois eventos **são** independentes: usar cupom não muda a chance de o cliente ser novo, e vice-versa. (Se a interseção informada fosse qualquer outro valor, eles seriam dependentes.)

18. (0,5) Num sistema de rastreamento de bugs, 60% dos bugs afetam o backend ($P(B) = 0,60$), 30% afetam o frontend ($P(F) = 0,30$) e 20% afetam os dois ao mesmo tempo ($P(B \cap F) = 0,20$). Qual é a probabilidade de um bug afetar o backend **ou** o frontend?

- (a) 0,90
- (b) 0,70
- (c) 1,10
- (d) 0,20
- (e) 0,50

Resolução

```
P(B ou F) = 0,70
sem subtrair a interseção = 0,90
somando a interseção = 1,10
subtraindo a interseção duas vezes = 0,50
```

Como os eventos se sobrepõem (20% dos bugs afetam os dois), a regra geral da adição subtrai a interseção uma vez: $P(B \cup F) = 0,60 + 0,30 - 0,20 = 0,70$. Resposta: **(b)**. Distratores: (a) 0,90 soma $P(B) + P(F)$ direto, sem subtrair a interseção — o erro clássico que conta duas vezes os bugs que afetam ambos; (c) 1,10 **soma** a interseção em vez de subtraí-la, chegando a um valor maior que 1, o que já viola o axioma $P \leq 1$; (d) confunde a interseção (0,20) com a união; (e) 0,50 subtrai a interseção **duas** vezes, tirando a mais do que a regra pede.

19. (0,5) Um sistema de suporte registrou os 200 chamados de um mês, cruzando o **canal** de entrada (Chat, E-mail, Telefone) com o fato de o chamado ter sido **resolvido no primeiro contato**:

Resolvido no 1º contato	Chat	E-mail	Telefone	Total
Sim	80	30	40	150
Não	20	20	10	50
Total	100	50	50	200

- (a) Qual a probabilidade de um chamado ser resolvido no primeiro contato, **dado** que entrou pelo Chat? (b) Use a regra da probabilidade total para obter a probabilidade de um chamado qualquer ser resolvido no primeiro contato. (c) Um chamado foi resolvido no primeiro contato; qual a probabilidade de que tenha entrado pelo Chat? (Bayes — inverta o condicionamento.)

Resolução

```
P(resolvido | Chat) = 0,800
P(resolvido) [prob. total] = 0,750
P(Chat | resolvido) [Bayes] = 0,533
```

(a) Sabendo que o chamado entrou pelo Chat, só interessam os 100 chamados dessa coluna; a fração resolvida no primeiro contato é 0,800 (80 de 100). (b) A regra da probabilidade total soma, sobre os três canais, a probabilidade de o chamado vir por aquele canal vezes a de ser resolvido dado o canal: $(0,50)(0,80) + (0,25)(0,60) + (0,25)(0,80) = 0,750$ — o mesmo que $150/200$, mas montado peça por peça, como uma média ponderada pelo volume de cada canal. (c) Bayes inverte o condicionamento — de “resolvido dado Chat”, que já se conhece, para “Chat dado resolvido”: $P(\text{Chat} \mid \text{resolvido}) = \frac{P(\text{resolvido} \mid \text{Chat}) \cdot P(\text{Chat})}{P(\text{resolvido})} = \frac{(0,80)(0,50)}{0,750} = 0,533$. Note a assimetria: $P(\text{resolvido} \mid \text{Chat}) = 0,800$ e $P(\text{Chat} \mid \text{resolvido}) = 0,533$ são números diferentes — cada condicional restringe o espaço amostral a um evento distinto.

20. (0,5) Um sistema de detecção de fraude tem **sensibilidade** de 90% (quando a transação é fraudulenta, o alarme dispara em 90% das vezes) e taxa de **falso-positivo** de 5% (quando a transação é legítima, o alarme dispara por engano em 5% das vezes). Apenas 2% das transações são realmente fraudulentas. O alarme acabou de disparar para uma transação. Qual a probabilidade de que ela seja, de fato, fraudulenta?

- (a) 90%
- (b) 26,9%
- (c) 5%
- (d) 2%
- (e) 1,8%

Resolução

$$\begin{aligned} P(\text{fraude e alarme}) &= 0,018 \\ P(\text{legítima e alarme}) &= 0,049 \\ P(\text{fraude} \mid \text{alarme}) &= 26,9\% \end{aligned}$$

Por Bayes, $P(\text{fraude} \mid \text{alarme}) = \frac{(0,02)(0,90)}{(0,02)(0,90) + (0,98)(0,05)} = 26,9\%$. Resposta: **(b)**. O denominador explica o número: os alarmes verdadeiros somam 0,018, mas os falsos alarmes das transações legítimas somam 0,049 — bem mais, porque as legítimas são 98% de tudo. Distratores: (a) 90% é a **armadilha da taxa-base** — trata a sensibilidade $P(\text{alarme} \mid \text{fraude})$ como se fosse o posterior $P(\text{fraude} \mid \text{alarme})$, ignorando que fraude é rara; (c) 5% é apenas a taxa de falso-positivo, outra condicional invertida; (d) 2% é a prevalência (o prior), que despreza a informação de que o alarme disparou; (e) 0,018 (1,8%) é só o numerador $P(\text{fraude e alarme})$, sem normalizar pela probabilidade total de o alarme disparar.

21. (0,5) Uma equipe tem 10 desenvolvedores. Para um novo projeto, o líder precisa formar uma força-tarefa de 3 pessoas, **sem** distinção de papel entre elas (os três terão a mesma função). De quantas formas diferentes essa força-tarefa pode ser montada?

- (a) 720
- (b) 1.000
- (c) 120
- (d) 30
- (e) 3.628.800

Resolução

$$\begin{aligned} C(10, 3) &= 120 \\ P(10, 3) &= 720 \\ 10^3 &= 1.000 \\ 10! &= 3.628.800 \end{aligned}$$

A pergunta que decide a fórmula é: a ordem importa? Não — os três membros têm a mesma função, então “escolher A, B, C” é a mesma força-tarefa que “escolher C, B, A”. É uma **combinação** de 3 entre 10: $\binom{10}{3} = 120$. Resposta: (c). Distratores: (a) 720 é $P(10, 3)$, a **permutação** — conta arranjos ordenados, apropriada só se os três cargos fossem distintos; usar **perm** onde a ordem não importa conta cada equipe $3! = 6$ vezes; (b) 1.000 é 10^3 , que contaria com reposição (a mesma pessoa ocupando mais de uma vaga); (d) 30 é 10×3 , uma multiplicação sem sentido combinatório; (e) $3.628.800$ é $10!$, a permutação de **todos** os 10, não a escolha de 3.

22. (0,5) Uma equipe de QA tem 12 casos de teste disponíveis. (a) De quantas maneiras ela pode **escolher** 4 casos para revisar, sem se importar com a ordem da revisão? (b) Se, em vez de apenas escolher, ela precisar definir uma **sequência ordenada** de execução para 4 dos 12 casos (a ordem importa), quantas sequências diferentes existem? (c) Explique a relação numérica entre os dois resultados.

Resolução

$$C(12, 4) = 495$$

$$P(12, 4) = 11.880$$

$$P(12, 4) / C(12, 4) = 24 = 4!$$

(a) Só escolher, sem ordem, é uma **combinação**: $\binom{12}{4} = \frac{12!}{4!8!} = 495$ maneiras. (b) Definir uma sequência ordenada é uma **permutação**: $P(12, 4) = 12 \times 11 \times 10 \times 9 = 11.880$ sequências. (c) A permutação é maior por um fator 24, que é exatamente $4!$: cada subconjunto de 4 casos (contado uma vez pela combinação) pode ser ordenado de $4! = 24$ maneiras diferentes, e a permutação conta todas elas. Por isso $\binom{12}{4} = \frac{P(12, 4)}{4!}$ — a combinação é a permutação dividida pelas ordenações que ela decidiu ignorar.

23. (0,5) Um lote pequeno de 15 microcontroladores acabou de chegar; sabe-se que 4 deles têm o firmware desatualizado. Um técnico retira 3 ao acaso, **sem reposição**, para inspeção. (a) Qual distribuição de probabilidade modela o número de microcontroladores desatualizados na amostra, e por quê? (b) Calcule a probabilidade de a amostra conter **exatamente 1** desatualizado. (c) Se o técnico devolvesse cada peça ao lote antes de retirar a próxima, qual distribuição passaria a valer, e com que probabilidade de sucesso?

Resolução

$$P(\text{exatamente 1 desatualizado}) = 0,484$$

$$p \text{ (se houvesse reposição)} = 4/15 = 0,267$$

(a) A amostragem é **sem reposição**, de um lote finito dividido em dois grupos (desatualizados e atualizados): a cada retirada, a proporção de desatualizados que resta muda, então a premissa de p constante da binomial quebra. A distribuição correta é a **hipergeométrica**. (b) Com $N = 15$ (lote), $r = 4$ (desatualizados) e $n = 3$ (amostra), $P(X = 1) = \frac{\binom{4}{1}\binom{11}{2}}{\binom{15}{3}} = 0,484$. (c) Com reposição, a proporção de desatualizados voltaria a ser constante a cada sorteio, e a distribuição passaria a ser a **binomial**, com $n = 3$ e $p = 4/15 = 0,267$. Como a amostra (3) é 20% do lote (15) — bem acima da regra dos 10% —, as duas distribuições dariam respostas visivelmente diferentes aqui, e só a hipergeométrica é exata para o sorteio sem reposição descrito.

24. (0,5) Numa página de checkout, a taxa real de conversão é $p = 0,20$. Num período, chegam 10 visitantes independentes. Qual a probabilidade de que **exatamente 3** deles convertam?

- (a) 0,002
- (b) 0,201
- (c) 0,300
- (d) 2
- (e) 0,107

Resolução

$P(\text{exatamente 3 em 10}) = 0,201$
 $p^3(1-p)^7$ (sem o coeficiente) = 0,002
 np (valor esperado) = 2
 $P(0 \text{ conversões}) = 0,107$

É uma **binomial** com $n = 10$ e $p = 0,20$: $P(X = 3) = \binom{10}{3}(0,20)^3(0,80)^7 = 0,201$. Resposta: **(b)**. Distratores: (a) 0,002 esquece o coeficiente binomial $\binom{10}{3} = 120$ e calcula só $p^3(1-p)^7$ — a probabilidade de uma sequência específica de 3 conversões e 7 não-conversões, não a de qualquer uma delas; (c) 0,300 usa a frequência relativa 3/10 como se fosse a probabilidade; (d) 2 reporta o valor esperado $np = 2$, que nem sequer é uma probabilidade (é o número médio de conversões, e passa de 1); (e) 0,107 calcula $P(0 \text{ conversões}) = 0,80^{10}$, respondendo à pergunta errada.

25. **(0,5)** De um conjunto de 20 servidores, sabe-se que 6 estão com uma configuração de segurança vulnerável. Uma auditoria sorteia 4 servidores **sem reposição** para inspeção. Qual a probabilidade de que **exatamente 2** dos 4 sorteados sejam vulneráveis?

- (a) 0,265
- (b) 0,282
- (c) 0,500
- (d) 0,003
- (e) 0,090

Resolução

$P(2 \text{ vulneráveis})$ hipergeométrica = 0,282
binomial (com reposição, $p=6/20$) = 0,265
 $C(6,2)/C(20,4) = 0,003$
 $(6/20)^2 = 0,090$

O sorteio é **sem reposição** de um lote finito, então a distribuição é a **hipergeométrica**: $P(X = 2) = \frac{\binom{6}{2}\binom{14}{2}}{\binom{20}{4}} = 0,282$. Resposta: **(b)**. Distratores: (a) 0,265 aplica a **binomial** com $p = 6/20$, supondo reposição — mas a amostra (4) é 20% do lote (20), longe dos 10% que justificariam a aproximação, então o número sai errado; (c) 0,500 toma 2/4, a fração da amostra, como probabilidade; (d) 0,003 é $\binom{6}{2}/\binom{20}{4}$ — esquece de escolher as 2 boas entre as 14 restantes no numerador; (e) 0,090 é só $(6/20)^2$, a chance de 2 vulneráveis “seguidas” sem o coeficiente nem os casos bons.

26. **(0,5)** Os tempos de resposta de uma API são aproximadamente normais, com média $\mu = 200$ ms e desvio-padrão $\sigma = 25$ ms. (a) Calcule o escore z de um tempo de 250 ms. (b) Pela regra empírica (68–95–99,7), entre quais valores caem cerca de 95% dos tempos? (c) Um tempo de 275 ms está a quantos desvios da média? Ele deve ser considerado raro? Justifique com a regra empírica.

Resolução

z de 250 ms = 2,0
95% dos tempos entre 150 e 250 ms
 z de 275 ms = 3,0
 $P(\text{tempo} > 275 \text{ ms}) = 0,13\%$

(a) O escore z padroniza o valor em número de desvios acima da média: $z = \frac{250-200}{25} = 2,0$. (b) A regra empírica diz que ~95% da massa cai a menos de dois desvios da média, ou seja, entre $\mu - 2\sigma = 150$ ms e

$\mu + 2\sigma = 250$ ms. (c) O tempo de 275 ms tem $z = \frac{275-200}{25} = 3,0$, ou seja, está a **três** desvios da média. Como ~99,7% dos tempos caem dentro de $\pm 3\sigma$, ultrapassar $+3\sigma$ acontece em menos de 0,3% dos casos (e, de um lado só, cerca de 0,13%) — sim, é um tempo raro, o tipo de valor que sinaliza uma anomalia digna de investigação.

27. (0,5) As notas finais de uma disciplina seguem, aproximadamente, uma distribuição normal com média 70 e desvio-padrão 8. Qual das afirmações abaixo está correta, pela regra empírica (68–95–99,7)?

- (a) Cerca de 68% das notas ficam entre 54 e 86.
- (b) Cerca de 95% das notas ficam entre 62 e 78.
- (c) Cerca de 95% das notas ficam entre 54 e 86.
- (d) Cerca de 99,7% das notas ficam entre 62 e 78.
- (e) Cerca de 68% das notas ficam entre 46 e 94.

Resolução

$\mu \pm 1\sigma$ ($\approx 68\%$): 62 a 78
 $\mu \pm 2\sigma$ ($\approx 95\%$): 54 a 86
 $\mu \pm 3\sigma$ ($\approx 99,7\%$): 46 a 94

Cada percentagem da regra empírica está atrelada a um número específico de desvios: ~68% a $\mu \pm 1\sigma$ (de 62 a 78), ~95% a $\mu \pm 2\sigma$ (de 54 a 86) e ~99,7% a $\mu \pm 3\sigma$ (de 46 a 94). Resposta: **(c)**, que parecia 95% com o intervalo de dois desvios. Distratores: todos trocam a percentagem pelo intervalo errado — (a) atribui os 68% ao intervalo de $\pm 2\sigma$; (b) atribui os 95% ao de $\pm 1\sigma$; (d) atribui os 99,7% ao de $\pm 1\sigma$; (e) atribui os 68% ao de $\pm 3\sigma$. Errar qual percentagem vai com qual largura é a confusão típica da regra empírica.

28. (0,5) Um analista modela os retornos diários de um ativo como normais, com média 0% e desvio-padrão 1%. Num pregão, o ativo cai 6% (um retorno de -6%). (a) Qual o escore z desse retorno? (b) Sob o modelo normal, a probabilidade de um retorno diário menor ou igual a -6% equivale a “1 em quantos”? (c) Sabendo que quedas dessa magnitude, no mundo real, acontecem a cada década ou duas, o que o resultado de (b) revela sobre a adequação do modelo normal para retornos financeiros?

Resolução

$z = -6$
 $P(\text{retorno} \leq -6\%)$ sob a normal ≈ 1 em 1.013.594.692
 ≈ 1 vez a cada 4.022.201 anos (a 252 pregões/ano)

(a) Padronizando, $z = \frac{-6-0}{1} = -6$ — o retorno está a seis desvios abaixo da média. (b) Sob a normal, $P(\text{retorno} \leq -6\%)$ é ínfima: cerca de **1 em 1.013.594.692** (mais de um bilhão), o que, a 252 pregões por ano, equivaleria a uma queda dessas a cada 4.022.201 anos — milhões de anos. (c) A realidade contradiz o modelo de forma gritante: quedas de 6% ocorrem a cada década ou duas, não a cada milhões de anos. A normal, portanto, **subestima drasticamente o risco de cauda** — os retornos têm **cauda gorda** (curtose alta), com eventos extremos muito mais frequentes do que a distribuição em sino admite. Modelar retornos como normais dá uma falsa sensação de segurança e é exatamente o erro que a seção 2.8 alerta contra.

29. (0,5) O tempo de build de um projeto segue, aproximadamente, uma distribuição normal com média 10 minutos e desvio-padrão 2 minutos. Usando a regra empírica (68–95–99,7), aproximadamente que fração dos builds **passa de 14 minutos**?

- (a) 5%
- (b) 2,5%
- (c) 16%

- (d) 32%
- (e) 95%

Resolução

$14 \text{ min} = \mu + 2\sigma = 14$
 acima de $+2\sigma$ (regra empírica) $\approx 2,5\%$
 acima de $+2\sigma$ (valor exato) $= 2,3\%$

O limite de 14 minutos é exatamente $\mu + 2\sigma = 10 + 2(2)$. A regra empírica diz que $\sim 95\%$ dos builds caem dentro de $\pm 2\sigma$, logo $\sim 5\%$ caem **fora** — e, como a normal é simétrica, metade desses fica acima de $+2\sigma$: $\sim 2,5\%$. Resposta: **(b)**. (O valor exato, $2,3\%$, confirma a estimativa.) Distratores: (a) 5% é a fração fora de $\pm 2\sigma$ **somando as duas caudas**, esquecendo que só metade está acima; (c) 16% é a fração acima de $+1\sigma$ — usa um desvio em vez de dois; (d) 32% é a fração fora de $\pm 1\sigma$ ($100 - 68$), errando o número de desvios e ainda somando as duas caudas; (e) 95% é a fração **dentro** de $\pm 2\sigma$, o oposto do que se pede.

30. (0,5) Um quiz de fixação tem 8 questões de múltipla escolha, cada uma com 4 alternativas e exatamente uma correta. Um aluno que não estudou responde todas **no chute**, escolhendo uma alternativa ao acaso em cada questão, de forma independente. (a) Quantos gabaritos de respostas diferentes são possíveis para o quiz inteiro? (b) Qual a probabilidade de o aluno acertar **exatamente 3** das 8 questões? (c) Qual a probabilidade de ele acertar **pelo menos 1** questão?

Resolução

gabaritos possíveis = 65.536
 $P(\text{exatamente 3 acertos}) = 0,208$
 $P(\text{ao menos 1 acerto}) = 0,900$

(a) Cada questão tem 4 respostas possíveis e são 8 questões independentes; pelo princípio multiplicativo, o total de gabaritos é $4^8 = 65.536$. (b) Cada questão é um “sucesso ou fracasso” independente, com $p = 1/4$ de acerto no chute — uma **binomial** com $n = 8$: $P(X = 3) = \binom{8}{3} \left(\frac{1}{4}\right)^3 \left(\frac{3}{4}\right)^5 = 0,208$. (c) “Pelo menos 1” sai mais fácil pelo complementar: $P(X \geq 1) = 1 - P(X = 0) = 1 - \left(\frac{3}{4}\right)^8 = 0,900$. Ou seja, mesmo chutando tudo, o aluno tem cerca de 90% de chance de acertar ao menos uma — mas acertar 3 exatas já é bem menos provável, e acertar muitas mais é raro, porque cada acerto extra multiplica por um fator $1/4$ cada vez menor.