

Lista 1: Prova 1

Bases 3: Estatística · Análise Exploratória e Probabilidade

Nome: _____ Matrícula: _____

Entrega: manuscrita, até 30/10/2026 · 30 questões · 0,5 ponto cada · 15 pontos

Você pode usar Python (Colab) como calculadora, mas as respostas devem ser **escritas à mão**. Nas questões abertas, mostre o raciocínio; nas fechadas, marque a letra e **justifique**.

Matriz de cobertura

Conferência do professor: cada seção dos Capítulos 1 (1.1 a 1.7; a 1.8 é leitura complementar) e 2 é tocada por ao menos uma questão. Exercícios integrativos aparecem em mais de uma linha.

Seção	Questões
1.1 Elementos de Dados Estruturados	1, 2, 10
1.2 Dados Retangulares	2
1.3 Estimativas de Localização	3, 4, 15
1.4 Estimativas de Variabilidade	5, 6, 7, 8, 14, 15
1.5 Explorando a Distribuição dos Dados	5, 7, 8, 15
1.6 Dados Binários e Categóricos	9, 10, 13
1.7 Correlação	11, 12
2.1 Modelos Probabilísticos	16, 28
2.2 Propriedades da Probabilidade	17, 18, 29
2.3 Contagem e Probabilidade Clássica	21, 22, 23, 25, 30
2.4 Probabilidade Condicional e Independência	17, 19, 24, 26, 30
2.5 O Teorema de Bayes	19, 20, 27

Bloco 1: Análise Exploratória de Dados

1. (0,5) Um sistema de matrícula universitária registra, entre outros, os campos abaixo para cada aluno:

Campo	Exemplo de valor
Matrícula	202301234
Situação (Ativo ou Trancado)	Ativo
Conceito final do período	B
Créditos cursados no período	12
CR (coeficiente de rendimento)	7,8

Qual alternativa classifica corretamente **todos** os cinco campos, na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário)?

- (a) Matrícula: numérico discreto; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (b) Matrícula: categórico nominal; Situação: ordinal; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (c) Matrícula: categórico nominal; Situação: binário; Conceito: categórico nominal; Créditos: numérico discreto; CR: numérico contínuo.
- (d) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico contínuo; CR: numérico contínuo.
- (e) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.

Resolução

Resposta: **(e)**. Matrícula é um identificador. Apesar do formato numérico, somar ou tirar a média de duas matrículas não significa nada, então é categórico nominal (o mesmo caso do CEP visto na seção 1.1). Situação (Ativo/Trancado) tem exatamente duas categorias, sem soma nem distância entre elas: binário. Conceito (A a E) tem ordem (B é melhor que D), mas não uma distância numérica definida entre as letras: ordinal. Créditos cursados é uma contagem, só assume valores inteiros: numérico discreto. CR é uma média com casas decimais, que pode assumir qualquer valor num intervalo: numérico contínuo.

Distratores: (a) trata a Matrícula como numérico discreto, o erro clássico de confundir um identificador com uma quantidade; (b) atribui ordem a Situação, que não tem nenhuma: “Ativo” não é “mais” nem “menos” que “Trancado”; (c) trata Conceito como nominal, perdendo a informação de ordem entre as notas; (d) trata Créditos cursados como numérico contínuo, ignorando que é uma contagem (nunca assume uma fração de crédito).

2. **(0,5)** Um cadastro de produtos de um e-commerce tem as seguintes variáveis: **SKU** (código do produto, ex.: **ELX-0234**), **Categoria** (Eletrônicos, Roupas, Alimentos, Livros), **Avaliação do cliente** (de 1 a 5 estrelas, em valores inteiros), **Quantidade em estoque** (unidades inteiras), **Preço unitário** (R\$, com centavos) e **Em promoção** (Sim/Não). Classifique cada uma das seis variáveis na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário), justificando cada resposta em uma frase.

Resolução

- **SKU**: categórico **nominal**. É um identificador; o formato alfanumérico não implica ordem nem distância entre dois códigos.
- **Categoria**: categórico **nominal**. Não há ordem natural entre Eletrônicos, Roupas, Alimentos e Livros.
- **Avaliação do cliente**: categórico **ordinal**. Há ordem (5 estrelas é melhor que 1), mas a distância entre “4” e “5” não é necessariamente igual à distância entre “1” e “2”.
- **Quantidade em estoque**: numérico **discreto**. É uma contagem de unidades, só assume valores inteiros.
- **Preço unitário**: numérico **contínuo**. Pode assumir qualquer valor dentro de um intervalo.
- **Em promoção**: categórico **binário**. Tem exatamente duas categorias, sem soma nem distância entre elas.

Cada produto é um registro (uma linha da tabela de cadastro); as seis variáveis acima são as colunas, as *features* que descrevem cada registro, na terminologia da seção 1.2.

3. **(0,5)** Um sistema de suporte técnico registrou o tempo de atendimento (em minutos) de 10 chamados consecutivos: 4, 5, 5, 6, 6, 7, 7, 8, 9 e 50 (este último passou por escalonamento e ficou muito tempo em fila). Calcule a média, a mediana e a média aparada de 10% desse conjunto. Qual dessas três medidas descreve melhor o tempo “típico” de atendimento, e por quê?

Resolução

```
média = 10,70 min  
mediana = 6,50 min  
média aparada (10%) = 6,625 min
```

A média é 10,70 minutos (bem acima da maioria dos chamados), porque o único chamado escalonado (50 minutos) puxa a soma para cima. A mediana, 6,50 minutos, e a média aparada de 10%, 6,62 minutos, ficam muito mais próximas do que a maioria dos chamados realmente levou: a mediana porque só enxerga o valor central, e a aparada porque descarta 1 observação de cada ponta antes de calcular a média (10% de 10 chamados = 1). A medida mais representativa do tempo “típico” é a mediana (ou a aparada). A média, aqui, é distorcida por um único outlier, o mesmo padrão de robustez discutido nas seções 1.3 a 1.5.

4. (0,5) Uma rede de lojas tem três filiais. A tabela abaixo mostra o valor médio de venda por cliente e o número de transações de cada filial em um mês.

Filial	Valor médio (R\$)	Transações
Centro	40	400
Norte	90	50
Sul	100	50

Qual das alternativas está correta?

- (a) A média simples dos três valores médios (R\$ 76,67) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois trata as três filiais com o mesmo peso.
- (b) A média ponderada pelo número de transações (R\$ 51,00) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois dá mais peso à filial com mais transações.
- (c) A média ponderada será sempre maior que a média simples quando os pesos são diferentes entre os grupos.
- (d) Como a filial Centro tem 400 transações (muito mais que as outras), sua média de R\$ 40 deve ser tratada como um outlier e descartada do cálculo.
- (e) A média ponderada e a média simples medem exatamente a mesma grandeza e, por isso, são sempre iguais.

Resolução

```
média simples = 76,67  
média ponderada = 51,00
```

A média simples é 76,67 e a média ponderada é 51,00. Resposta: **(b)**. Distratores: (a) trata as filiais como se tivessem o mesmo tamanho, ignorando que Centro sozinho responde por 400 das 500 transações, o mesmo erro que compararia a taxa de homicídios simples dos estados com a ponderada sem levar a população em conta; (c) é falso neste próprio exemplo: a ponderada (51,00) é **menor** que a simples (76,67), porque a maior filial tem a menor média (a direção depende dos dados, não é uma lei geral); (d) confunde “grupo grande” com “outlier”: outlier é um valor atípico dentro de uma distribuição, não uma categoria numerosa; (e) é o erro oposto de (c): supor que as duas médias são sempre iguais ignora que elas respondem perguntas diferentes, e coincidem, por exemplo, quando os pesos são iguais.

5. (0,5) Um time de QA registrou o número de erros encontrados por dia, ao longo de 9 dias de testes de um novo sistema: 2, 3, 3, 4, 5, 5, 6, 7, 9. Calcule a variância amostral, o desvio-padrão amostral e o IQR ($q_3 - q_1$).

com os quartis pela regra de posição $(n - 1)p + 1$ da seção 1.4) desse conjunto. Em seguida, escreva uma frase interpretando o IQR no contexto do problema.

Resolução

```
média = 4,89  
variância amostral = 4,86  
desvio-padrão amostral = 2,20  
Q1 = 3,0    Q3 = 6,0  
IQR = 3,0
```

A variância amostral é 4,86 e o desvio-padrão amostral é 2,20 erros/dia. O IQR é 3,0 (de $q_1 = 3,0$ a $q_3 = 6,0$). Interpretação: os 50% centrais dos 9 dias de teste tiveram entre 3,0 e 6,0 erros por dia. É uma faixa bem mais estreita que a variação total (de 2 a 9), o que mostra que a maioria dos dias ficou concentrada num intervalo pequeno, com poucos dias puxando as pontas.

6. (0,5) As notas de uma avaliação de 5 alunos são: 6, 7, 7, 8, 12. Qual das alternativas apresenta corretamente o desvio-padrão amostral, a variância amostral e a amplitude total (máximo – mínimo) desse conjunto (arredondados a 2 casas quando necessário)?

- (a) desvio-padrão = 5,50; variância = 2,35; amplitude = 6
- (b) desvio-padrão = 2,35; variância = 5,50; amplitude = 6
- (c) desvio-padrão = 2,10; variância = 4,40; amplitude = 6
- (d) desvio-padrão = 2,35; variância = 5,50; amplitude = 12
- (e) desvio-padrão = 4,69; variância = 22,00; amplitude = 6

Resolução

```
variância amostral = 5,50  
desvio-padrão amostral = 2,35  
amplitude = 6
```

Variância = 5,50; desvio-padrão = 2,35; amplitude = 6. Resposta: **(b)**. Distratores: (a) inverte desvio-padrão e variância: o desvio-padrão é sempre a **raiz** da variância; (c) usa n no denominador em vez de $n - 1$ (divide a soma dos quadrados dos desvios por 5 em vez de 4), o erro clássico de usar a fórmula populacional numa amostra; (d) confunde amplitude com o valor máximo, esquecendo de subtrair o mínimo; (e) esquece de dividir a soma dos quadrados dos desvios (22) por $n - 1$, reportando a soma bruta como se fosse a variância, e tira a raiz dessa soma bruta para chegar a um “desvio-padrão” que não é.

7. (0,5) As idades (em anos) de 9 clientes cadastrados em uma loja, já em ordem crescente, são: 18, 20, 22, 25, 27, 30, 33, 35, 40. Qual das alternativas apresenta corretamente o primeiro quartil (q_1), o terceiro quartil (q_3) e o IQR desse conjunto, calculados pela regra de posição $(n - 1)p + 1$ da seção 1.4?

- (a) $q_1 = 20$; $q_3 = 35$; IQR = 15
- (b) $q_1 = 22$; $q_3 = 33$; IQR = 11
- (c) $q_1 = 22$; $q_3 = 33$; IQR = 55
- (d) $q_1 = 25$; $q_3 = 30$; IQR = 5
- (e) $q_1 = 18$; $q_3 = 40$; IQR = 22

Resolução

```
Q1 = 22
Q3 = 33
IQR = 11
```

$q_1 = 22$; $q_3 = 33$; $IQR = 11$. Resposta: **(b)**. Distratores: (a) usa as posições vizinhas erradas (a 2ª e a 8ª observações, em vez da 3ª e da 7ª); (c) soma q_3 e q_1 em vez de subtrair: o IQR é sempre uma diferença, nunca uma soma; (d) confunde quartil com os valores logo ao lado da mediana (4ª e 6ª observações); (e) confunde quartil com os extremos do conjunto (mínimo e máximo), que marcariam a amplitude total, não a amplitude interquartil.

8. **(0,5)** O resumo de cinco números de um conjunto de dados é: mínimo = 6, $q_1 = 20$, mediana = 22, $q_3 = 30$, máximo = 68. (a) Calcule o IQR e os limites do bigode pela regra de $1,5 \times IQR$. (b) O mínimo e o máximo são outliers? (c) Descreva a forma da distribuição: a posição da mediana dentro da caixa e a assimetria provável.

Resolução

```
IQR = 10,0
limite inferior = 5,0
limite superior = 45,0
mínimo é outlier? não
máximo é outlier? sim
```

$IQR = 10,0$. Limite inferior do bigode = 5,0; limite superior = 45,0. O mínimo (6) está **acima** do limite inferior (5). Não é outlier, e o bigode inferior se estende até ele. O máximo (68) está muito **acima** do limite superior (45). É um outlier, desenhado como ponto isolado; o bigode superior real vai só até o maior valor não-outlier (≤ 45). Quanto à forma: a mediana (22) está a apenas 2 unidades de q_1 (20) e a 8 unidades de q_3 (30), portanto mais perto do lado de baixo da caixa, e o outlier fica acima. Os dois sinais apontam na mesma direção: mediana deslocada para o lado de baixo da caixa e cauda (com o outlier) para a direita, ou seja, **assimetria positiva**.

9. **(0,5)** Um sistema de e-commerce registra o método de pagamento de 200 pedidos: Cartão de crédito (120), Boleto (50), Pix (30). Qual das alternativas está correta?

- (a) A moda dessa variável é “Cartão de crédito”, pois é o método mais frequente (60% dos pedidos).
- (b) A média dos três valores (120, 50, 30) representa o método de pagamento típico dos pedidos.
- (c) Como “Pix” tem a menor contagem, ele deve ser excluído da análise por ser um outlier.
- (d) Cada método de pagamento tem probabilidade de $1/3$ (33,3%), pois há três categorias possíveis.
- (e) A mediana dessa variável categórica é “Boleto”, por ter contagem intermediária.

Resolução

```
Cartão de crédito: 60,0%
Boleto: 25,0%
Pix: 15,0%
moda = Cartão de crédito
```

As proporções são 60%, 25% e 15%, calculadas acima; a moda é Cartão de crédito. Resposta: **(a)**. Distratores: (b) tenta calcular a média de uma variável nominal: não há soma nem ordem entre métodos de pagamento, a operação não significa nada; (c) confunde “categoria rara” com “outlier”: outlier é um valor atipicamente distante da distribuição de uma variável numérica, não a categoria menos frequente de uma nominal (a mesma armadilha do exercício da causa “Segurança” nos atrasos de voo, seção 1.6); (d) confunde “número

de categorias” com “distribuição uniforme”: três categorias não implicam três probabilidades iguais; a distribuição real é bem desigual (60/25/15); (e) tenta calcular uma mediana de categorias nominais, que não têm ordem entre si (a ordem em que as categorias aparecem na tabela é arbitrária).

10. (0,5) Uma operadora de telecomunicações registra os motivos de reclamação de 250 clientes em um mês:

Motivo	Frequência
Cobrança indevida	120
Queda de sinal	80
Atendimento	40
Outro	10

- (a) Calcule a proporção de cada motivo e identifique a moda. (b) Um colega propõe calcular a “média” e a “mediana” do motivo de reclamação. Isso faz sentido? Justifique pelo tipo da variável. (c) Que gráfico é adequado para mostrar essa distribuição, e por quê?

Resolução

Cobrança indevida: 48,0%
 Queda de sinal: 32,0%
 Atendimento: 16,0%
 Outro: 4,0%

- (a) As proporções são 48,0%, 32,0%, 16,0% e 4,0%. A moda é “Cobrança indevida”, a categoria mais frequente. (b) Não faz sentido. O motivo é uma variável categórica nominal: não há soma entre categorias (média) nem ordem entre elas (mediana), e a ordem das linhas na tabela é arbitrária. Para variáveis nominais, os resumos são as proporções e a moda. (c) Um gráfico de barras, com barras separadas e eixo começando em zero: o eixo horizontal é categórico, e a altura de cada barra deve ser proporcional à contagem ou à proporção.

11. (0,5) Um estudo com trabalhadores encontra uma correlação de Pearson $r = -0,82$ entre “horas de sono por noite” e “número de erros cometidos em uma tarefa de digitação”. Qual das alternativas está correta?

- (a) Como r é negativo e próximo de -1 , há uma associação linear forte: mais horas de sono tendem a estar associadas a menos erros. Mas isso, sozinho, não prova que dormir mais causa a redução de erros. (b) $r = -0,82$ significa que dormir mais horas causa, necessariamente, uma redução no número de erros. (c) Como r é negativo, não existe associação alguma entre as duas variáveis. (d) $r = -0,82$ indica uma associação fraca, pois está distante do valor mínimo possível, -2 . (e) Se as horas de sono fossem medidas em minutos em vez de horas, o valor de r mudaria substancialmente.

Resolução

Resposta: **(a)**. O sinal negativo indica que as duas variáveis se movem em direções opostas (mais sono, menos erros), e a magnitude (0,82, próxima de 1) indica associação linear forte. Mesmo assim, correlação não é prova de causalidade: uma terceira variável (por exemplo, o nível geral de estresse ou a carga de trabalho) poderia afetar sono e desempenho ao mesmo tempo. Distratores: (b) comete o erro clássico de tratar correlação como causa; (c) confunde sinal negativo com ausência de associação: um r negativo indica uma **direção** de associação, não a falta dela (é o valor 0, não o sinal, que indicaria ausência de relação linear); (d) supõe que r pode variar além do intervalo $[-1, 1]$, o que é matematicamente impossível: o denominador da fórmula de Pearson garante que $|r| \leq 1$; (e) ignora que r é adimensional: converter horas em minutos é uma transformação linear, e a correlação de Pearson é invariante a mudanças de escala e unidade.

12. (0,5) Uma pesquisadora relaciona horas semanais de estudo (x) e nota em uma avaliação, de 0 a 100 (y), de 6 estudantes: (2, 50), (4, 55), (6, 65), (8, 70), (10, 80), (12, 100). Calcule o coeficiente de correlação de Pearson entre x e y (mostre as somas intermediárias) e interprete o valor obtido. Essa correlação, por si só, permite concluir que estudar mais **causa** uma nota maior? Justifique.

Resolução

```
média de  $x = 7,0$     média de  $y = 70,0$   
soma dos produtos cruzados = 330,0  
soma dos desvios2 de  $x = 70,0$     soma dos desvios2 de  $y = 1.650,0$   
 $r = 0,971$ 
```

$r = 0,971$. É uma correlação positiva e muito forte: horas de estudo maiores estão associadas a notas mais altas, de forma quase perfeitamente linear nesta amostra. Mas r mede apenas associação, não causa: um terceiro fator (motivação do estudante, conhecimento prévio da matéria, tempo disponível fora do trabalho) pode influenciar tanto as horas de estudo quanto o desempenho na prova, gerando essa associação sem que estudar “cause” a nota diretamente. Além disso, com apenas 6 pontos, um único par atípico teria grande influência sobre r . É a segunda armadilha da correlação: sensibilidade a outliers.

13. (0,5) Um painel de monitoramento mostra o tempo médio de resposta de três serviços: A com 210 ms, B com 220 ms e C com 240 ms, num gráfico de barras cujo eixo vertical começa em 200 ms. Olhando o gráfico, a barra de C parece ter quatro vezes a altura da barra de A. Qual alternativa está correta?

- (a) O gráfico está correto: C é de fato quatro vezes mais lento que A.
- (b) O eixo truncado exagera a diferença. As barras medem só o quanto cada serviço passa de 200 ms (10, 20 e 40 ms); o tempo de C é cerca de 1,14 vezes o de A, ou seja, 14% maior.
- (c) Como os valores são próximos, qualquer gráfico de barras vai esconder a diferença; o certo é não usar gráfico.
- (d) O problema é o gráfico ser de barras; num gráfico de pizza, a comparação ficaria correta.
- (e) O eixo truncado só é problema quando os valores são negativos.

Resolução

```
alturas no gráfico (ms acima de 200): {'A': 10, 'B': 20, 'C': 40}  
razão entre as alturas C/A = 4,0  
razão entre os tempos C/A = 1,14
```

Resposta: **(b)**. Com o eixo começando em 200 ms, a altura de cada barra mostra só o excesso sobre 200: 10, 20 e 40 ms. A razão entre as alturas de C e A é 4, mas a razão entre os tempos é 1,14. É o mesmo efeito da seção 1.6 com a taxa do Piauí. Distratores: (a) lê a altura da barra como se o eixo começasse em zero; (c) a solução é começar o eixo em zero, e não abandonar o gráfico; (d) o problema é o eixo, e não o tipo de gráfico; a pizza, aliás, compara partes de um todo, o que não é o caso de tempos de resposta; (e) o truncamento distorce qualquer comparação de alturas, com valores positivos ou negativos.

14. (0,5) Os tempos de resposta (em ms) de 8 requisições a um serviço foram: 120, 125, 130, 128, 122, 135, 127 e 900 (a última pegou um *timeout* do banco de dados). (a) Calcule a média, o desvio-padrão amostral, a mediana e o desvio absoluto mediano (MAD, com o fator 0,6745 usado na seção 1.4). (b) Recalcule as quatro medidas sem a requisição de 900 ms. (c) Quais medidas mudaram muito e quais quase não mudaram? Explique por quê.

Resolução

```
média: com o timeout = 223,4    sem = 126,7
desvio-padrão: com o timeout = 273,4    sem = 5,0
mediana: com o timeout = 127,5    sem = 127,0
MAD: com o timeout = 5,9    sem = 4,4
```

(a) Com as 8 requisições: média 223,4 ms, desvio-padrão 273,4 ms, mediana 127,5 ms e MAD 5,9 ms. (b) Sem a de 900 ms: média 126,7, desvio-padrão 5,0, mediana 127,0 e MAD 4,4. (c) A média e o desvio-padrão mudam muito: um único valor extremo entra na soma, e no desvio-padrão ele ainda é elevado ao quadrado. A mediana e o MAD mudam pouco (o MAD cai de 5,9 para 4,4 ms, enquanto o desvio-padrão cai de 273,4 para 5,0), porque dependem só dos valores do meio da fila ordenada. Por isso a mediana e o MAD são as estimativas robustas da seção 1.4: com o *timeout*, a média de 223 ms não descreve nenhuma requisição típica.

15. (0,5) As notas de 7 alunos em uma prova foram: 60, 62, 65, 68, 70, 72 e 5 (o último aluno entregou a prova em branco, exceto por uma questão). Qual das alternativas está correta?

- (a) A média (57,43) é maior que a mediana (65), porque o outlier baixo eleva a média.
- (b) A média (57,43) é menor que a mediana (65), porque a nota 5 é um outlier baixo que puxa a média para baixo, enquanto a mediana permanece próxima do grosso das notas.
- (c) O desvio-padrão é uma medida mais robusta que a mediana diante desse outlier, pois usa todas as observações no cálculo.
- (d) Remover o outlier não afetaria a mediana, mas afetaria bastante a média; por isso, a mediana deve sempre substituir a média em qualquer conjunto de dados.
- (e) Como a média é menor que a mediana, a distribuição dessas notas é assimétrica à direita.

Resolução

```
média = 57,43
mediana = 65,00
```

Média = 57,43; mediana = 65,00. Resposta: **(b)**. Distratores: (a) inverte o sentido da comparação (a média não é maior, é menor) e inverte o efeito do outlier (um outlier baixo puxa a média para **baixo**, não para cima); (c) é o oposto da verdade: o desvio-padrão eleva os desvios ao quadrado, o que o torna **ainda mais** sensível a extremos que a própria média; usar “todas as observações” não é sinônimo de robustez, é exatamente a razão da fragilidade; (d) parte de uma premissa falsa, porque remover o outlier também muda a mediana (de 65 para 66,5), só que pouco; e generaliza demais: a mediana é preferível quando há outliers ou cauda longa plausível, mas isso não significa que ela deva “sempre” substituir a média (para dados simétricos e sem outliers, a média é tão boa quanto, e mais eficiente estatisticamente); (e) inverte a regra da seção 1.5: média menor que a mediana é o sinal de assimetria à **esquerda** (negativa), não à direita. A regra é “assimetria positiva → cauda à direita → média maior que a mediana”, e aqui o sinal está trocado.

Bloco 2: Probabilidade

16. (0,5) Um teste A/B mostra a versão A ou a versão B da página a cada usuário, sorteando com a mesma chance e de forma independente. Três usuários acessam a página. Um colega afirma: “o número de usuários que viram a versão A pode ser 0, 1, 2 ou 3; são quatro resultados, então cada um tem probabilidade 1/4”. Qual alternativa está correta?

- (a) O colega está certo: são quatro resultados possíveis, e a definição clássica dá 1/4 para cada um.

- (b) O colega errou ao supor que os quatro resultados são igualmente prováveis. O espaço amostral com pontos equiprováveis são as 8 sequências de três letras (AAA, AAB, ..., BBB), e “exatamente 2 viram A” tem probabilidade $3/8$.
- (c) O colega errou, porque a probabilidade de cada resultado é $1/3$, já que são três usuários.
- (d) Não é possível calcular nada sem saber qual versão converte mais.
- (e) “Exatamente 2 viram A” tem probabilidade $2/3$, a proporção de usuários que viram A.

Resolução

```
espaço amostral: ['AAA', 'AAB', 'ABA', 'ABB', 'BAA', 'BAB', 'BBA', 'BBB']
{0: 1, 1: 3, 2: 3, 3: 1}
```

Resposta: **(b)**. Pelo princípio multiplicativo, há $2^3 = 8$ sequências igualmente prováveis. O número de usuários que viram A é um espaço amostral válido, $\{0, 1, 2, 3\}$, mas seus pontos não têm a mesma chance: 0 e 3 correspondem a uma sequência cada; 1 e 2, a três sequências cada. Então $P(\text{exatamente 2 viram A}) = 3/8$. É o erro do “número de caras” da seção 2.1. Distratores: (a) aplica a definição clássica a pontos que não são equiprováveis; (c) confunde o número de usuários com o número de resultados; (d) a conversão não entra na pergunta, que é só sobre qual versão foi mostrada; (e) confunde uma proporção dentro de um resultado com a probabilidade desse resultado.

17. (0,5) Numa loja virtual, 40% dos clientes usam algum cupom de desconto ($P(C) = 0,40$), 25% são clientes novos ($P(N) = 0,25$) e 10% usam cupom e são novos ($P(C \cap N) = 0,10$). (a) Qual a probabilidade de um cliente usar cupom **ou** ser novo? (b) Qual a probabilidade de um cliente **não** usar cupom? (c) Os eventos “usar cupom” e “ser cliente novo” são independentes? Justifique pela definição.

Resolução

```
P(cupom ou novo) = 0,55
P(não usar cupom) = 0,60
P(C) · P(N) = 0,10    P(C e N) = 0,10
```

(a) Os dois eventos podem ocorrer juntos (um cliente novo pode usar cupom), então a regra da adição precisa subtrair a interseção: $P(C \cup N) = P(C) + P(N) - P(C \cap N) = 0,55$. (b) Pelo complementar, $P(C^c) = 1 - P(C) = 0,60$. (c) A definição de independência exige $P(C \cap N) = P(C) \cdot P(N)$. Aqui $P(C) \cdot P(N) = 0,10$, exatamente igual ao $P(C \cap N) = 0,10$ informado, então os dois eventos **são** independentes: usar cupom não muda a chance de o cliente ser novo, e vice-versa. (Se a interseção informada fosse qualquer outro valor, eles seriam dependentes.)

18. (0,5) Num sistema de rastreamento de bugs, 60% dos bugs afetam o backend ($P(B) = 0,60$), 30% afetam o frontend ($P(F) = 0,30$) e 20% afetam os dois ao mesmo tempo ($P(B \cap F) = 0,20$). Qual é a probabilidade de um bug afetar o backend **ou** o frontend?

- (a) 0,90
 (b) 0,70
 (c) 1,10
 (d) 0,20
 (e) 0,50

Resolução

```
P(B ou F) = 0,70
sem subtrair a interseção = 0,90
```

somando a interseção = 1,10
 subtraindo a interseção duas vezes = 0,50

Como os eventos se sobrepõem (20% dos bugs afetam os dois), a regra geral da adição subtrai a interseção uma vez: $P(B \cup F) = 0,60 + 0,30 - 0,20 = 0,70$. Resposta: **(b)**. Distratores: (a) 0,90 soma $P(B) + P(F)$ direto, sem subtrair a interseção: é o erro clássico que conta duas vezes os bugs que afetam ambos; (c) 1,10 **soma** a interseção em vez de subtraí-la, chegando a um valor maior que 1, o que já viola o axioma $P \leq 1$; (d) confunde a interseção (0,20) com a união; (e) 0,50 subtrai a interseção **duas** vezes, tirando a mais do que a regra pede.

19. (0,5) Um sistema de suporte registrou os 200 chamados de um mês, cruzando o **canal** de entrada (Chat, E-mail, Telefone) com o fato de o chamado ter sido **resolvido no primeiro contato**:

Resolvido no 1º contato	Chat	E-mail	Telefone	Total
Sim	80	30	40	150
Não	20	20	10	50
Total	100	50	50	200

- (a) Qual a probabilidade de um chamado ser resolvido no primeiro contato, **dado** que entrou pelo Chat? (b) Use a regra da probabilidade total para obter a probabilidade de um chamado qualquer ser resolvido no primeiro contato. (c) Um chamado foi resolvido no primeiro contato; qual a probabilidade de que tenha entrado pelo Chat? (Bayes: inverta o condicionamento.)

Resolução

$P(\text{resolvido} \mid \text{Chat}) = 0,800$
 $P(\text{resolvido}) [\text{prob. total}] = 0,750$
 $P(\text{Chat} \mid \text{resolvido}) [\text{Bayes}] = 0,533$

- (a) Sabendo que o chamado entrou pelo Chat, só interessam os 100 chamados dessa coluna; a fração resolvida no primeiro contato é 0,800 (80 de 100). (b) A regra da probabilidade total soma, sobre os três canais, a probabilidade de o chamado vir por aquele canal vezes a de ser resolvido dado o canal: $(0,50)(0,80) + (0,25)(0,60) + (0,25)(0,80) = 0,750$. É o mesmo que $150/200$, mas montado peça por peça, como uma média ponderada pelo volume de cada canal. (c) Bayes inverte o condicionamento, de “resolvido dado Chat” (que já se conhece) para “Chat dado resolvido”: $P(\text{Chat} \mid \text{resolvido}) = \frac{P(\text{resolvido} \mid \text{Chat}) \cdot P(\text{Chat})}{P(\text{resolvido})} = \frac{(0,80)(0,50)}{0,75} = 0,533$. Note a assimetria: $P(\text{resolvido} \mid \text{Chat}) = 0,800$ e $P(\text{Chat} \mid \text{resolvido}) = 0,533$ são números diferentes. Cada condicional restringe o espaço amostral a um evento distinto.

20. (0,5) Um sistema de detecção de fraude tem **sensibilidade** de 90% (quando a transação é fraudulenta, o alarme dispara em 90% das vezes) e taxa de **falso-positivo** de 5% (quando a transação é legítima, o alarme dispara por engano em 5% das vezes). Apenas 2% das transações são realmente fraudulentas. O alarme acabou de disparar para uma transação. Qual a probabilidade de que ela seja, de fato, fraudulenta?

- (a) 90%
 (b) 26,9%
 (c) 5%
 (d) 2%
 (e) 1,8%

Resolução

$$\begin{aligned}P(\text{fraude e alarme}) &= 0,018 \\P(\text{legítima e alarme}) &= 0,049 \\P(\text{fraude} \mid \text{alarme}) &= 26,9\%\end{aligned}$$

Por Bayes, $P(\text{fraude} \mid \text{alarme}) = \frac{(0,02)(0,90)}{(0,02)(0,90) + (0,98)(0,05)} = 26,9\%$. Resposta: **(b)**. O denominador explica o número: os alarmes verdadeiros somam 0,018, mas os falsos alarmes das transações legítimas somam 0,049. É bem mais, porque as legítimas são 98% de tudo. Distratores: (a) 90% é a **armadilha da taxa-base**: trata a sensibilidade $P(\text{alarme} \mid \text{fraude})$ como se fosse o posterior $P(\text{fraude} \mid \text{alarme})$, ignorando que fraude é rara; (c) 5% é apenas a taxa de falso-positivo, outra condicional invertida; (d) 2% é a prevalência (o prior), que despreza a informação de que o alarme disparou; (e) 0,018 (1,8%) é só o numerador $P(\text{fraude e alarme})$, sem normalizar pela probabilidade total de o alarme disparar.

21. (0,5) Uma equipe tem 10 desenvolvedores. Para um novo projeto, o líder precisa formar uma força-tarefa de 3 pessoas, **sem** distinção de papel entre elas (os três terão a mesma função). De quantas formas diferentes essa força-tarefa pode ser montada?

- (a) 720
- (b) 1.000
- (c) 120
- (d) 30
- (e) 3.628.800

Resolução

$$\begin{aligned}\text{comb}(10, 3) &= 120 \\10 \cdot 9 \cdot 8 &= 720 \\10^3 &= 1.000 \\10! &= 3.628.800\end{aligned}$$

A pergunta que decide a fórmula é: a ordem importa? Não. Os três membros têm a mesma função, então “escolher A, B, C” é a mesma força-tarefa que “escolher C, B, A”. É uma **combinação** de 3 entre 10: $\binom{10}{3} = 120$. Resposta: **(c)**. Distratores: (a) 720 é $10 \times 9 \times 8$, a **permutação** de 3 entre 10 (conta arranjos ordenados, apropriada só se os três cargos fossem distintos); usar **perm** onde a ordem não importa conta cada equipe $3! = 6$ vezes; (b) 1.000 é 10^3 , que contaria com reposição (a mesma pessoa ocupando mais de uma vaga); (d) 30 é 10×3 , uma multiplicação sem sentido combinatório; (e) 3.628.800 é $10!$, a permutação de **todos** os 10, não a escolha de 3.

22. (0,5) Uma equipe de QA tem 12 casos de teste disponíveis. (a) De quantas maneiras ela pode **escolher** 4 casos para revisar, sem se importar com a ordem da revisão? (b) Se, em vez de apenas escolher, ela precisar definir uma **sequência ordenada** de execução para 4 dos 12 casos (a ordem importa), quantas sequências diferentes existem? (c) Explique a relação numérica entre os dois resultados.

Resolução

$$\begin{aligned}\text{comb}(12, 4) &= 495 \\12 \cdot 11 \cdot 10 \cdot 9 &= 11.880 \\razão &= 24 = 4!\end{aligned}$$

(a) Só escolher, sem ordem, é uma **combinação**: $\binom{12}{4} = \frac{12!}{4!8!} = 495$ maneiras. (b) Definir uma sequência ordenada é uma **permutação**: $12 \times 11 \times 10 \times 9 = 11.880$ sequências. (c) A permutação é maior por um

fator 24, que é exatamente $4!$: cada subconjunto de 4 casos (contado uma vez pela combinação) pode ser ordenado de $4! = 24$ maneiras diferentes, e a permutação conta todas elas. Por isso $\binom{12}{4} = \frac{12 \times 11 \times 10 \times 9}{4!}$: a combinação é a permutação dividida pelas ordenações que ela decidiu ignorar.

23. (0,5) Um lote pequeno de 15 microcontroladores acabou de chegar; sabe-se que 4 deles têm o firmware desatualizado. Um técnico retira 3 ao acaso, **sem reposição** e sem se importar com a ordem, para inspeção. (a) Quantas amostras diferentes de 3 microcontroladores são possíveis? (b) Qual a probabilidade de a amostra conter **exatamente 1** desatualizado? (c) Qual a probabilidade de a amostra conter **pelo menos 1** desatualizado?

Resolução

```
amostras possíveis = 455
P(exatamente 1) = 0,484
P(nenhum) = 0,363    P(pelo menos 1) = 0,637
```

- (a) A ordem não importa, então são combinações de 3 entre 15: $\binom{15}{3} = 455$ amostras, todas com a mesma chance, porque o sorteio é ao acaso. (b) Um caso favorável escolhe 1 desatualizado entre os 4 e 2 atualizados entre os 11: $\binom{4}{1}\binom{11}{2} = 4 \times 55 = 220$ casos. A probabilidade é $220/455$, cerca de 0,484. (c) Pelo complementar, “pelo menos 1” é o contrário de “nenhum”, e nenhum desatualizado significa escolher os 3 entre os 11 atualizados: $1 - \binom{11}{3}/\binom{15}{3}$, cerca de 0,637.

24. (0,5) Uma API de pedidos só responde se três serviços funcionarem: autenticação (confiabilidade 0,99), pagamentos (0,97) e catálogo (0,98). Suponha que os três falhem de forma independente. (a) Qual a confiabilidade da API? (b) O serviço de pagamentos ganha uma réplica, com a mesma confiabilidade 0,97, e basta uma das duas cópias funcionar. Qual passa a ser a confiabilidade da API? (c) Se as duas cópias de pagamentos rodarem no mesmo servidor, a conta de (b) continua valendo? Explique.

Resolução

```
série: 0,9411
pagamentos com réplica: 0,9991
API com a réplica: 0,9693
```

- (a) Em série, a API funciona se os três funcionarem. Com independência, as confiabilidades se multiplicam: $0,99 \times 0,97 \times 0,98$, cerca de 0,9411, abaixo do pior componente. (b) As duas cópias estão em paralelo: o serviço de pagamentos só falha se as duas falharem, com probabilidade $0,03^2$. Sua confiabilidade vira $1 - 0,03^2 = 0,9991$, e a da API passa a 0,9693. (c) Não. A conta supõe falhas independentes. No mesmo servidor, as duas cópias tendem a cair juntas (queda de energia, disco cheio), a chance de as duas falharem fica maior que $0,03^2$, e a réplica protege menos do que a fórmula promete.

25. (0,5) De um conjunto de 20 servidores, sabe-se que 6 estão com uma configuração de segurança vulnerável. Uma auditoria sorteia, ao acaso, 4 servidores **sem reposição** para inspeção. Qual a probabilidade de que **exatamente 2** dos 4 sorteados sejam vulneráveis?

- (a) 0,265
- (b) 0,282
- (c) 0,500
- (d) 0,003
- (e) 0,090

Resolução

```
P(2 vulneráveis) = 0,282  
se houvesse reposição = 0,265  
comb(6, 2)/comb(20, 4) = 0,003  
(6/20)2 = 0,090
```

É a mesma conta da auditoria de pull requests da seção 2.3. Os casos possíveis são os $\binom{20}{4}$ subconjuntos de 4 servidores. Um caso favorável escolhe 2 vulneráveis entre os 6 e 2 seguros entre os 14: $P = \frac{\binom{6}{2}\binom{14}{2}}{\binom{20}{4}}$, cerca de 0,282. Resposta: **(b)**. Distratores: (a) 0,265 trata os sorteios como independentes, com a mesma chance 6/20 em cada um, como se o servidor voltasse ao conjunto depois de sorteado, e multiplica pelas $\binom{4}{2} = 6$ posições possíveis dos 2 vulneráveis; mas o sorteio é sem reposição; (c) 0,500 toma 2/4, a fração da amostra, como probabilidade; (d) 0,003 esquece de escolher os 2 seguros entre os 14 no numerador; (e) 0,090 é só $(6/20)^2$, sem contar os casos.

26. **(0,5)** Uma fila tem 10 tickets de suporte, 4 urgentes e 6 normais. Um atendente pega dois tickets ao acaso, um depois do outro, **sem devolver** o primeiro à fila. (a) Qual a probabilidade de os dois serem urgentes? (b) Qual a probabilidade de o **segundo** ticket ser urgente? (c) Os eventos “o primeiro é urgente” e “o segundo é urgente” são independentes? Justifique.

Resolução

```
P(U1 e U2) = 2/15  
P(U2) = 2/5  
P(U1) · P(U2) = 4/25
```

(a) Pela regra do produto, $P(U_1 \cap U_2) = P(U_1) P(U_2 | U_1) = \frac{4}{10} \times \frac{3}{9} = \frac{2}{15}$. (b) O segundo é urgente por dois caminhos disjuntos da árvore, UU e NU: $\frac{4}{10} \times \frac{3}{9} + \frac{6}{10} \times \frac{4}{9} = \frac{2}{5}$, a mesma chance do primeiro. (c) Não são independentes. $P(U_1) P(U_2) = \frac{2}{5} \times \frac{2}{5} = \frac{4}{25}$, diferente de $P(U_1 \cap U_2) = \frac{2}{15}$. Sem reposição, saber que o primeiro foi urgente muda a composição da fila: $P(U_2 | U_1) = \frac{3}{9}$, e não $\frac{2}{5}$.

27. **(0,5)** Os builds de um projeto rodam em três máquinas: 60% na máquina A, 30% na B e 10% na C. Por problemas de ambiente, a taxa de falha espúria (falha que não vem do código) é de 2% na A, 5% na B e 20% na C. Um build acabou de ter uma falha espúria. Qual a probabilidade de ele ter rodado na máquina C?

- (a) 10%
- (b) 20%
- (c) 42,6%
- (d) 4,7%
- (e) 2%

Resolução

```
P(falha) = 0,047  
P(máquina | falha): ['0,255', '0,319', '0,426']
```

As três máquinas formam uma partição. Pela probabilidade total, $P(\text{falha}) = 0,60 \times 0,02 + 0,30 \times 0,05 + 0,10 \times 0,20 = 0,047$. Por Bayes, $P(C | \text{falha}) = \frac{0,10 \times 0,20}{0,047}$, cerca de 42,6%. Resposta: **(c)**. Só 10% dos builds rodam na máquina C, mas ela responde por mais de 40% das falhas espúrias, porque sua taxa de falha é muito maior. Distratores: (a) é a priori $P(C)$, sem usar a informação da falha; (b) é a verossimilhança $P(\text{falha} | C)$, a condicional invertida; (d) é $P(\text{falha})$, o denominador; (e) é a taxa de falha da máquina A.

28. (0,5) O Nordeste tem 9 das 27 unidades federativas. (a) Sorteando uma unidade federativa ao acaso, qual a probabilidade de ela ser do Nordeste? (b) Agora sorteia-se um **brasileiro** ao acaso, e a pergunta é se ele mora no Nordeste. A resposta é a mesma de (a)? Use `dados/estados.csv` (colunas `Sigla` e `Populacao`; as siglas do Nordeste são MA, PI, CE, RN, PB, PE, AL, SE e BA) para calcular. (c) Explique a diferença entre os dois modelos.

Resolução

$P(\text{UF do Nordeste}) = 0,333$
 $P(\text{brasileiro no Nordeste}) = 0,269$

(a) Com as 27 unidades equiprováveis, $P = 9/27 = 1/3$. (b) Não. Sorteando uma pessoa, cada unidade federativa pesa a fração da população que mora nela, e a probabilidade é a soma das populações do Nordeste dividida pela população total: cerca de 0,269. (c) O evento é o mesmo conjunto de 9 siglas nos dois casos, mas o modelo muda: no primeiro, cada ponto amostral tem probabilidade $1/27$; no segundo, cada sigla tem probabilidade proporcional à sua população. Como o Nordeste tem uma fatia da população menor que um terço, a probabilidade por pessoa fica abaixo de $1/3$.

29. (0,5) Num sistema, a probabilidade de falha de disco num dia é 0,10, a de falha de rede é 0,15 e a de as duas falharem no mesmo dia é 0,03. Qual a probabilidade de **nenhuma** das duas falhas ocorrer num dia?

- (a) 0,75
- (b) 0,765
- (c) 0,78
- (d) 0,97
- (e) 0,22

Resolução

$P(\text{disco ou rede}) = 0,22$
 $P(\text{nenhuma}) = 0,78$

Sejam D e R os eventos “falha de disco” e “falha de rede”. “Nenhuma falha” é o complementar de “pelo menos uma falha” (lei de De Morgan: $D^c \cap R^c = (D \cup R)^c$). Pela regra da adição, $P(D \cup R) = 0,10 + 0,15 - 0,03 = 0,22$, e $P(\text{nenhuma}) = 1 - 0,22 = 0,78$. Resposta: **(c)**. Distratores: (a) esquece de descontar a interseção e faz $1 - 0,25$; (b) multiplica $0,90 \times 0,85$, o que supõe independência, mas os dados dizem que não há ($0,10 \times 0,15 = 0,015 \neq 0,03$); (d) é o complementar só da interseção, $1 - 0,03$, que é a chance de não falharem **as duas juntas**; (e) é $P(D \cup R)$, a probabilidade de pelo menos uma falha.

30. (0,5) Um quiz de fixação tem 8 questões de múltipla escolha, cada uma com 4 alternativas e exatamente uma correta. Um aluno que não estudou responde todas **no chute**, escolhendo uma alternativa ao acaso em cada questão, de forma independente. (a) Quantas folhas de resposta diferentes são possíveis para o quiz inteiro? (b) Qual a probabilidade de o aluno acertar **todas** as 8 questões? (c) Qual a probabilidade de ele acertar **pelo menos 1** questão?

Resolução

folhas de resposta possíveis = 65.536
 $P(\text{acertar todas}) = 1/65.536$
 $P(\text{ao menos 1 acerto}) = 0,999$

(a) Cada questão tem 4 respostas possíveis e são 8 questões; pelo princípio multiplicativo, o total de folhas de resposta é $4^8 = 65.536$. (b) Só uma dessas folhas acerta tudo, e todos são igualmente prováveis no chute:

$P = 1/4^8 = (1/4)^8$, ou 1 em 65.536. Pela independência, dá o mesmo que multiplicar $1/4$ por si mesmo oito vezes. (c) “Pelo menos 1” sai mais fácil pelo complementar. Errar uma questão tem probabilidade $3/4$, e errar todas, pela independência, $(3/4)^8$. Então $P(\text{pelo menos 1}) = 1 - (3/4)^8$, cerca de 0,900: mesmo chutando tudo, o aluno quase sempre acerta alguma.