

Lista 1 — Prova 1

Bases 3 — Estatística · Análise Exploratória e Probabilidade

Nome: _____ Matrícula: _____

Entrega: manuscrita, até 16/10/2026 · 30 questões · 0,5 ponto cada · 15 pontos

Você pode usar Python (Colab) como calculadora, mas as respostas devem ser **escritas à mão**. Nas questões abertas, mostre o raciocínio; nas fechadas, marque a letra e **justifique**.

Bloco 1 — Análise Exploratória de Dados

1. (0,5) Um sistema de matrícula universitária registra, entre outros, os campos abaixo para cada aluno:

Campo	Exemplo de valor
Matrícula	202301234
Situação	Ativo
Conceito final do período	B
Créditos cursados no período	12
CR (coeficiente de rendimento)	7,8

Qual alternativa classifica corretamente **todos** os cinco campos, na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário)?

- (a) Matrícula: numérico discreto; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (b) Matrícula: categórico nominal; Situação: ordinal; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (c) Matrícula: categórico nominal; Situação: binário; Conceito: categórico nominal; Créditos: numérico discreto; CR: numérico contínuo.
- (d) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico contínuo; CR: numérico contínuo.
- (e) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.

2. (0,5) Um cadastro de produtos de um e-commerce tem as seguintes variáveis: **SKU** (código do produto, ex.: **ELX-0234**), **Categoria** (Eletrônicos, Roupas, Alimentos, Livros), **Avaliação média dos clientes** (de 1 a 5 estrelas, em passos inteiros), **Quantidade em estoque** (unidades inteiras), **Preço unitário** (R\$, com centavos) e **Em promoção** (Sim/Não). Classifique cada uma das seis variáveis na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário), justificando cada resposta em uma frase.

3. (0,5) Um sistema de suporte técnico registrou o tempo de atendimento (em minutos) de 10 chamados consecutivos: 4, 5, 5, 6, 6, 7, 7, 8, 9 e 50 (este último passou por escalonamento e ficou muito tempo em fila). Calcule a média, a mediana e a média aparada de 10% desse conjunto. Qual dessas três medidas descreve melhor o tempo “típico” de atendimento, e por quê?

4. (0,5) Uma rede de lojas tem três filiais. A tabela abaixo mostra o valor médio de venda por cliente e o número de transações de cada filial em um mês.

Filial	Valor médio (R\$)	Transações
Centro	40	400
Norte	90	50
Sul	100	50

Qual das alternativas está correta?

- (a) A média simples dos três valores médios (R\$ 76,67) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois trata as três filiais com o mesmo peso.
- (b) A média ponderada pelo número de transações (R\$ 51,00) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois dá mais peso à filial com mais transações.
- (c) A média ponderada será sempre maior que a média simples quando os pesos são diferentes entre os grupos.
- (d) Como a filial Centro tem 400 transações — muito mais que as outras —, sua média de R\$ 40 deve ser tratada como um outlier e descartada do cálculo.
- (e) A média ponderada e a média simples medem exatamente a mesma grandeza e, por isso, são sempre iguais.

5. (0,5) Um time de QA registrou o número de erros encontrados por dia, ao longo de 9 dias de testes de um novo sistema: 2, 3, 3, 4, 5, 5, 6, 7, 9. Calcule a variância amostral, o desvio-padrão amostral e o IQR ($Q_3 - Q_1$) desse conjunto. Em seguida, escreva uma frase interpretando o IQR no contexto do problema.

6. (0,5) As notas de uma avaliação de 5 alunos são: 6, 7, 7, 8, 12. Qual das alternativas apresenta corretamente o desvio-padrão amostral, a variância amostral e a amplitude total (máximo – mínimo) desse conjunto (arredondados a 2 casas quando necessário)?

- (a) desvio-padrão = 5,50; variância = 2,35; amplitude = 6
- (b) desvio-padrão = 2,35; variância = 5,50; amplitude = 6
- (c) desvio-padrão = 2,10; variância = 4,40; amplitude = 6
- (d) desvio-padrão = 2,35; variância = 5,50; amplitude = 12
- (e) desvio-padrão = 4,69; variância = 22,00; amplitude = 6

7. (0,5) As idades (em anos) de 9 clientes cadastrados em uma loja, já em ordem crescente, são: 18, 20, 22, 25, 27, 30, 33, 35, 40. Qual das alternativas apresenta corretamente o primeiro quartil (Q_1), o terceiro quartil (Q_3) e o IQR desse conjunto?

- (a) $Q_1 = 20$; $Q_3 = 35$; IQR = 15
- (b) $Q_1 = 22$; $Q_3 = 33$; IQR = 11
- (c) $Q_1 = 22$; $Q_3 = 33$; IQR = 55
- (d) $Q_1 = 25$; $Q_3 = 30$; IQR = 5
- (e) $Q_1 = 18$; $Q_3 = 40$; IQR = 22

8. (0,5) O resumo de cinco números de um conjunto de dados é: mínimo = 6, $Q_1 = 20$, mediana = 22, $Q_3 = 30$, máximo = 68. (a) Calcule o IQR e os limites do bigode pela regra de $1,5 \times \text{IQR}$. (b) O mínimo e o máximo são outliers? (c) Descreva a forma da distribuição — a posição da mediana dentro da caixa e a assimetria provável.

9. (0,5) Um sistema de e-commerce registra o método de pagamento de 200 pedidos: Cartão de crédito (120), Boleto (50), Pix (30). Qual das alternativas está correta?

- (a) A moda dessa variável é “Cartão de crédito”, pois é o método mais frequente (60% dos pedidos).
- (b) A média dos três valores (120, 50, 30) representa o método de pagamento típico dos pedidos.
- (c) Como “Pix” tem a menor contagem, ele deve ser excluído da análise por ser um outlier.
- (d) Cada método de pagamento tem probabilidade de $1/3$ (33,3%), pois há três categorias possíveis.
- (e) A mediana dessa variável categórica é “Boleto”, por ter contagem intermediária.

10. (0,5) Uma operadora de telecomunicações registra os motivos de reclamação de 250 clientes em um mês, com o custo médio de resolução de cada tipo:

Motivo	Frequência	Custo de resolução (R\$)
Cobrança indevida	120	50
Queda de sinal	80	30
Atendimento	40	20
Outro	10	100

Calcule a proporção de cada motivo, identifique a moda, e calcule o valor esperado do custo de resolução por reclamação. Por que o motivo “Outro”, apesar de ter o maior custo unitário, contribui pouco para o valor esperado total?

11. (0,5) Um estudo com trabalhadores encontra uma correlação de Pearson $r = -0,82$ entre “horas de sono por noite” e “número de erros cometidos em uma tarefa de digitação”. Qual das alternativas está correta?

- (a) Como r é negativo e próximo de -1 , há uma associação linear forte: mais horas de sono tendem a estar associadas a menos erros — mas isso, sozinho, não prova que dormir mais causa a redução de erros.
- (b) $r = -0,82$ significa que dormir mais horas causa, necessariamente, uma redução no número de erros.
- (c) Como r é negativo, não existe associação alguma entre as duas variáveis.
- (d) $r = -0,82$ indica uma associação fraca, pois está distante do valor mínimo possível, -2 .
- (e) Se as horas de sono fossem medidas em minutos em vez de horas, o valor de r mudaria substancialmente.

12. (0,5) Uma pesquisadora relaciona horas semanais de estudo (x) e nota em uma avaliação, de 0 a 100 (y), de 6 estudantes: (2, 50), (4, 55), (6, 65), (8, 70), (10, 80), (12, 100). Calcule o coeficiente de correlação de Pearson entre x e y (mostre as somas intermediárias) e interprete o valor obtido. Essa correlação, por si só, permite concluir que estudar mais **causa** uma nota maior? Justifique.

13. (0,5) A tabela abaixo mostra a situação de pagamento de empréstimos de duas notas de risco:

Nota	Em dia	Inadimplente	Total
A	170	30	200
B	35	15	50

Qual das alternativas está correta?

- (a) A nota A é mais arriscada que a nota B, pois tem mais empréstimos inadimplentes em número absoluto (30 contra 15).
- (b) A taxa de inadimplência da nota B (30%) é maior que a da nota A (15%); logo, B é a nota mais arriscada, mesmo tendo bem menos empréstimos no total.
- (c) Como a nota A tem quatro vezes mais empréstimos que a nota B, sua taxa de inadimplência também deveria ser proporcionalmente maior.
- (d) É impossível comparar o risco das duas notas, porque elas têm números totais de empréstimos muito diferentes.

- (e) Somando as duas notas, há 45 empréstimos inadimplentes em 250 no total (18%); esse número agregado já mostra que as duas notas têm risco parecido.

14. (0,5) Duas técnicas de recuperação de servidores após falha, P e Q, foram testadas em incidentes de dois tipos — leves e graves. A tabela abaixo mostra quantos incidentes foram recuperados dentro do prazo de SLA (sucesso) em cada combinação de técnica e tipo:

Tipo de incidente	Técnica	Sucessos	Total de incidentes
Leve	P	180	200
Leve	Q	47	50
Grave	P	10	50
Grave	Q	36	150

- (a) Calcule a taxa de sucesso de P e de Q em cada tipo de incidente. (b) Calcule a taxa de sucesso agregada (somando os dois tipos) de P e de Q. (c) Há uma inversão entre o resultado por tipo e o resultado agregado? Qual variável escondida (confundidora) provoca essa inversão, e por quê?

15. (0,5) As notas de 7 alunos em uma prova foram: 60, 62, 65, 68, 70, 72 e 5 (o último aluno entregou a prova em branco, exceto por uma questão). Qual das alternativas está correta?

- (a) A média (57,43) é maior que a mediana (65), porque o outlier baixo eleva a média.
(b) A média (57,43) é menor que a mediana (65), porque a nota 5 é um outlier baixo que puxa a média para baixo, enquanto a mediana permanece próxima do grosso das notas.
(c) O desvio-padrão é uma medida mais robusta que a mediana diante desse outlier, pois usa todas as observações no cálculo.
(d) Remover o outlier não afetaria a mediana, mas afetaria bastante a média; por isso, a mediana deve sempre substituir a média em qualquer conjunto de dados.
(e) Como a média é menor que a mediana, a distribuição dessas notas é assimétrica à direita.

Bloco 2 — Probabilidade e Distribuições

16. (0,5) Numa reunião de planejamento, uma equipe de dados afirma: “a probabilidade de o próximo deploy quebrar a produção é 0,15”. Sobre essa afirmação e sobre o conceito de probabilidade, qual alternativa está correta?

- (a) A afirmação não faz sentido: como um deploy específico ou quebra ou não quebra a produção, probabilidade só se aplica a experimentos que podem ser repetidos infinitas vezes nas mesmas condições.
(b) O número 0,15 é mais naturalmente lido como um grau de crença (visão bayesiana), atualizável quando chegar nova evidência; a leitura frequentista teria de reinterpretá-lo como a fração de deploys “parecidos com este”, no histórico, que quebraram a produção.
(c) Na visão frequentista, 0,15 é um grau de crença subjetivo do time; na visão bayesiana, é uma frequência de longo prazo.
(d) Como há apenas dois resultados possíveis (quebra ou não quebra), cada um tem probabilidade 0,5 — logo o valor 0,15 está necessariamente errado.
(e) A afirmação é frequentista pelo simples fato de atribuir um número entre 0 e 1 ao evento.

17. (0,5) Numa loja virtual, 40% dos clientes usam algum cupom de desconto ($P(C) = 0,40$), 25% são clientes novos ($P(N) = 0,25$) e 10% usam cupom e são novos ($P(C \cap N) = 0,10$). (a) Qual a probabilidade de um cliente usar cupom **ou** ser novo? (b) Qual a probabilidade de um cliente **não** usar cupom? (c) Os eventos “usar cupom” e “ser cliente novo” são independentes? Justifique pela definição.

18. (0,5) Num sistema de rastreamento de bugs, 60% dos bugs afetam o backend ($P(B) = 0,60$), 30% afetam o frontend ($P(F) = 0,30$) e 20% afetam os dois ao mesmo tempo ($P(B \cap F) = 0,20$). Qual é a probabilidade de um bug afetar o backend **ou** o frontend?

- (a) 0,90
- (b) 0,70
- (c) 1,10
- (d) 0,20
- (e) 0,50

19. (0,5) Um sistema de suporte registrou os 200 chamados de um mês, cruzando o **canal** de entrada (Chat, E-mail, Telefone) com o fato de o chamado ter sido **resolvido no primeiro contato**:

Resolvido no 1º contato	Chat	E-mail	Telefone	Total
Sim	80	30	40	150
Não	20	20	10	50
Total	100	50	50	200

(a) Qual a probabilidade de um chamado ser resolvido no primeiro contato, **dado** que entrou pelo Chat? (b) Use a regra da probabilidade total para obter a probabilidade de um chamado qualquer ser resolvido no primeiro contato. (c) Um chamado foi resolvido no primeiro contato; qual a probabilidade de que tenha entrado pelo Chat? (Bayes — inverta o condicionamento.)

20. (0,5) Um sistema de detecção de fraude tem **sensibilidade** de 90% (quando a transação é fraudulenta, o alarme dispara em 90% das vezes) e taxa de **falso-positivo** de 5% (quando a transação é legítima, o alarme dispara por engano em 5% das vezes). Apenas 2% das transações são realmente fraudulentas. O alarme acabou de disparar para uma transação. Qual a probabilidade de que ela seja, de fato, fraudulenta?

- (a) 90%
- (b) 26,9%
- (c) 5%
- (d) 2%
- (e) 1,8%

21. (0,5) Uma equipe tem 10 desenvolvedores. Para um novo projeto, o líder precisa formar uma força-tarefa de 3 pessoas, **sem** distinção de papel entre elas (os três terão a mesma função). De quantas formas diferentes essa força-tarefa pode ser montada?

- (a) 720
- (b) 1.000
- (c) 120
- (d) 30
- (e) 3.628.800

22. (0,5) Uma equipe de QA tem 12 casos de teste disponíveis. (a) De quantas maneiras ela pode **escolher** 4 casos para revisar, sem se importar com a ordem da revisão? (b) Se, em vez de apenas escolher, ela precisar definir uma **sequência ordenada** de execução para 4 dos 12 casos (a ordem importa), quantas sequências diferentes existem? (c) Explique a relação numérica entre os dois resultados.

23. (0,5) Um lote pequeno de 15 microcontroladores acabou de chegar; sabe-se que 4 deles têm o firmware desatualizado. Um técnico retira 3 ao acaso, **sem reposição**, para inspeção. (a) Qual distribuição de probabilidade modela o número de microcontroladores desatualizados na amostra, e por quê? (b) Calcule a

probabilidade de a amostra conter **exatamente 1** desatualizado. (c) Se o técnico devolvesse cada peça ao lote antes de retirar a próxima, qual distribuição passaria a valer, e com que probabilidade de sucesso?

24. (0,5) Numa página de checkout, a taxa real de conversão é $p = 0,20$. Num período, chegam 10 visitantes independentes. Qual a probabilidade de que **exatamente 3** deles convertam?

- (a) 0,002
- (b) 0,201
- (c) 0,300
- (d) 2
- (e) 0,107

25. (0,5) De um conjunto de 20 servidores, sabe-se que 6 estão com uma configuração de segurança vulnerável. Uma auditoria sorteia 4 servidores **sem reposição** para inspeção. Qual a probabilidade de que **exatamente 2** dos 4 sorteados sejam vulneráveis?

- (a) 0,265
- (b) 0,282
- (c) 0,500
- (d) 0,003
- (e) 0,090

26. (0,5) Os tempos de resposta de uma API são aproximadamente normais, com média $\mu = 200$ ms e desvio-padrão $\sigma = 25$ ms. (a) Calcule o escore z de um tempo de 250 ms. (b) Pela regra empírica (68–95–99,7), entre quais valores caem cerca de 95% dos tempos? (c) Um tempo de 275 ms está a quantos desvios da média? Ele deve ser considerado raro? Justifique com a regra empírica.

27. (0,5) As notas finais de uma disciplina seguem, aproximadamente, uma distribuição normal com média 70 e desvio-padrão 8. Qual das afirmações abaixo está correta, pela regra empírica (68–95–99,7)?

- (a) Cerca de 68% das notas ficam entre 54 e 86.
- (b) Cerca de 95% das notas ficam entre 62 e 78.
- (c) Cerca de 95% das notas ficam entre 54 e 86.
- (d) Cerca de 99,7% das notas ficam entre 62 e 78.
- (e) Cerca de 68% das notas ficam entre 46 e 94.

28. (0,5) Um analista modela os retornos diários de um ativo como normais, com média 0% e desvio-padrão 1%. Num pregão, o ativo cai 6% (um retorno de –6%). (a) Qual o escore z desse retorno? (b) Sob o modelo normal, a probabilidade de um retorno diário menor ou igual a –6% equivale a “1 em quantos”? (c) Sabendo que quedas dessa magnitude, no mundo real, acontecem a cada década ou duas, o que o resultado de (b) revela sobre a adequação do modelo normal para retornos financeiros?

29. (0,5) Ao analisar os retornos diários de um ativo, um analista mede assimetria (skewness) próxima de 0 e curtose (kurtosis, na convenção da scipy em que a normal vale 0) igual a 8. Qual das afirmações está correta?

- (a) Curtose alta com assimetria ≈ 0 indica caudas pesadas nos **dois** lados (cauda gorda simétrica); num QQ-plot contra a normal, os pontos formariam um S.
- (b) Curtose alta significa que a distribuição é assimétrica à direita.
- (c) Assimetria ≈ 0 garante que os dados são normais, qualquer que seja a curtose.
- (d) Curtose alta indica que os valores extremos são **menos** frequentes do que numa normal.
- (e) Num QQ-plot, caudas pesadas fazem os pontos caírem exatamente sobre a reta.

30. (0,5) Um quiz de fixação tem 8 questões de múltipla escolha, cada uma com 4 alternativas e exatamente uma correta. Um aluno que não estudou responde todas **no chute**, escolhendo uma alternativa ao acaso em cada questão, de forma independente. (a) Quantos gabaritos de respostas diferentes são possíveis para o quiz

inteiro? (b) Qual a probabilidade de o aluno acertar **exatamente 3** das 8 questões? (c) Qual a probabilidade de ele acertar **pelo menos 1** questão?