Lista 1: Prova 1

Bases 3: Estatística · Análise Exploratória e Probabilidade

Nome: _____ **Matrícula:** _____

Entrega: manuscrita, até 06/11/2026 · **30 questões · 0,5 ponto cada · 15 pontos**

> Você pode usar Python (Colab) como calculadora, mas as respostas devem ser **escritas à mão**. Nas questões abertas, mostre o raciocínio; nas fechadas, marque a letra **e justifique**.

Bloco 1: Análise Exploratória de Dados

1. (0,5) Um sistema de matrícula universitária registra, entre outros, os campos abaixo para cada aluno:

Campo	Exemplo de valor
Matrícula	202301234
Situação (Ativo ou Trancado)	Ativo
Conceito final do período	B
Créditos cursados no período	12
CR (coeficiente de rendimento)	7,8

Qual alternativa classifica corretamente **todos** os cinco campos, na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário)?

(a) Matrícula: numérico discreto; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
(b) Matrícula: categórico nominal; Situação: ordinal; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
(c) Matrícula: categórico nominal; Situação: binário; Conceito: categórico nominal; Créditos: numérico discreto; CR: numérico contínuo.
(d) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico contínuo; CR: numérico contínuo.
(e) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.

2. (0,5) Um cadastro de produtos de um e-commerce tem as seguintes variáveis: **SKU** (código do produto, ex.: `ELX-0234`), **Categoria** (Eletrônicos, Roupas, Alimentos, Livros), **Avaliação do cliente** (de 1 a 5 estrelas, em valores inteiros), **Quantidade em estoque** (unidades inteiras), **Preço unitário** (R$, com centavos) e **Em promoção** (Sim/Não). Classifique cada uma das seis variáveis na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário), justificando cada resposta em uma frase.

3. (0,5) Um sistema de suporte técnico registrou o tempo de atendimento (em minutos) de 10 chamados consecutivos: 4, 5, 5, 6, 6, 7, 7, 8, 9 e 50 (este último passou por escalonamento e ficou muito tempo em fila). Calcule a média, a mediana e a média aparada de 10% desse conjunto. Qual dessas três medidas descreve melhor o tempo "típico" de atendimento, e por quê?

4. (0,5) Uma rede de lojas tem três filiais. A tabela abaixo mostra o valor médio de venda por cliente e o número de transações de cada filial em um mês.

Filial	Valor médio (R$)	Transações
Centro	40	400
Norte	90	50
Sul	100	50

Qual das alternativas está correta?

(a) A média simples dos três valores médios (R$ 76,67) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois trata as três filiais com o mesmo peso.
(b) A média ponderada pelo número de transações (R$ 51,00) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois dá mais peso à filial com mais transações.
(c) A média ponderada será sempre maior que a média simples quando os pesos são diferentes entre os grupos.
(d) Como a filial Centro tem 400 transações (muito mais que as outras), sua média de R$ 40 deve ser tratada como um outlier e descartada do cálculo.
(e) A média ponderada e a média simples medem exatamente a mesma grandeza e, por isso, são sempre iguais.

5. (0,5) Um time de QA registrou o número de erros encontrados por dia, ao longo de 9 dias de testes de um novo sistema: 2, 3, 3, 4, 5, 5, 6, 7, 9. Calcule a variância amostral, o desvio-padrão amostral e o IQR ($q_3 - q_1$, com os quartis pela regra de posição $(n-1)p+1$ da seção 1.4) desse conjunto. Em seguida, escreva uma frase interpretando o IQR no contexto do problema.

6. (0,5) As notas de uma avaliação de 5 alunos são: 6, 7, 7, 8, 12. Qual das alternativas apresenta corretamente o desvio-padrão amostral, a variância amostral e a amplitude total (máximo – mínimo) desse conjunto (arredondados a 2 casas quando necessário)?

(a) desvio-padrão = 5,50; variância = 2,35; amplitude = 6
(b) desvio-padrão = 2,35; variância = 5,50; amplitude = 6
(c) desvio-padrão = 2,10; variância = 4,40; amplitude = 6
(d) desvio-padrão = 2,35; variância = 5,50; amplitude = 12
(e) desvio-padrão = 4,69; variância = 22,00; amplitude = 6

7. (0,5) As idades (em anos) de 9 clientes cadastrados em uma loja, já em ordem crescente, são: 18, 20, 22, 25, 27, 30, 33, 35, 40. Qual das alternativas apresenta corretamente o primeiro quartil (q_1), o terceiro quartil (q_3) e o IQR desse conjunto, calculados pela regra de posição $(n-1)p+1$ da seção 1.4?

(a) $q_1 = 20$; $q_3 = 35$; IQR $= 15$
(b) $q_1 = 22$; $q_3 = 33$; IQR $= 11$
(c) $q_1 = 22$; $q_3 = 33$; IQR $= 55$
(d) $q_1 = 25$; $q_3 = 30$; IQR $= 5$
(e) $q_1 = 18$; $q_3 = 40$; IQR $= 22$

8. (0,5) O resumo de cinco números de um conjunto de dados é: mínimo $= 6$, $q_1 = 20$, mediana $= 22$, $q_3 = 30$, máximo $= 68$. (a) Calcule o IQR e os limites do bigode pela regra de 1,5×IQR. (b) O mínimo e o máximo são outliers? (c) Descreva a forma da distribuição: a posição da mediana dentro da caixa e a assimetria provável.

9. (0,5) Um sistema de e-commerce registra o método de pagamento de 200 pedidos: Cartão de crédito (120), Boleto (50), Pix (30). Qual das alternativas está correta?

(a) A moda dessa variável é "Cartão de crédito", pois é o método mais frequente (60% dos pedidos).
(b) A média dos três valores (120, 50, 30) representa o método de pagamento típico dos pedidos.
(c) Como "Pix" tem a menor contagem, ele deve ser excluído da análise por ser um outlier.
(d) Cada método de pagamento tem probabilidade de 1/3 (33,3%), pois há três categorias possíveis.
(e) A mediana dessa variável categórica é "Boleto", por ter contagem intermediária.

10. (0,5) Uma operadora de telecomunicações registra os motivos de reclamação de 250 clientes em um mês:

Motivo	Frequência
Cobrança indevida	120
Queda de sinal	80
Atendimento	40
Outro	10

(a) Calcule a proporção de cada motivo e identifique a moda. (b) Um colega propõe calcular a "média" e a "mediana" do motivo de reclamação. Isso faz sentido? Justifique pelo tipo da variável. (c) Que gráfico é adequado para mostrar essa distribuição, e por quê?

11. (0,5) Um estudo com trabalhadores encontra uma correlação de Pearson $r = -0,82$ entre "horas de sono por noite" e "número de erros cometidos em uma tarefa de digitação". Qual das alternativas está correta?

(a) Como r é negativo e próximo de -1, há uma associação linear forte: mais horas de sono tendem a estar associadas a menos erros. Mas isso, sozinho, não prova que dormir mais causa a redução de erros.
(b) $r = -0,82$ significa que dormir mais horas causa, necessariamente, uma redução no número de erros.
(c) Como r é negativo, não existe associação alguma entre as duas variáveis.
(d) $r = -0,82$ indica uma associação fraca, pois está distante do valor mínimo possível, -2.
(e) Se as horas de sono fossem medidas em minutos em vez de horas, o valor de r mudaria substancialmente.

12. (0,5) Uma pesquisadora relaciona horas semanais de estudo (x) e nota em uma avaliação, de 0 a 100 (y), de 6 estudantes: $(2, 50)$, $(4, 55)$, $(6, 65)$, $(8, 70)$, $(10, 80)$, $(12, 100)$. Calcule o coeficiente de correlação de Pearson entre x e y (mostre as somas intermediárias) e interprete o valor obtido. Essa correlação, por si só, permite concluir que estudar mais **causa** uma nota maior? Justifique.

13. (0,5) Um painel de monitoramento mostra o tempo médio de resposta de três serviços: A com 210 ms, B com 220 ms e C com 240 ms, num gráfico de barras cujo eixo vertical começa em 200 ms. Olhando o gráfico, a barra de C parece ter quatro vezes a altura da barra de A. Qual alternativa está correta?

(a) O gráfico está correto: C é de fato quatro vezes mais lento que A.
(b) O eixo truncado exagera a diferença. As barras medem só o quanto cada serviço passa de 200 ms (10, 20 e 40 ms); o tempo de C é cerca de 1,14 vezes o de A, ou seja, 14% maior.
(c) Como os valores são próximos, qualquer gráfico de barras vai esconder a diferença; o certo é não usar gráfico.
(d) O problema é o gráfico ser de barras; num gráfico de pizza, a comparação ficaria correta.
(e) O eixo truncado só é problema quando os valores são negativos.

14. (0,5) Os tempos de resposta (em ms) de 8 requisições a um serviço foram: 120, 125, 130, 128, 122, 135, 127 e 900 (a última pegou um *timeout* do banco de dados). (a) Calcule a média, o desvio-padrão amostral, a mediana e o desvio absoluto mediano (MAD, com o fator 0,6745 usado na seção 1.4). (b) Recalcule as quatro medidas sem a requisição de 900 ms. (c) Quais medidas mudaram muito e quais quase não mudaram? Explique por quê.

15. (0,5) As notas de 7 alunos em uma prova foram: 60, 62, 65, 68, 70, 72 e 5 (o último aluno entregou a prova em branco, exceto por uma questão). Qual das alternativas está correta?

(a) A média (57,43) é maior que a mediana (65), porque o outlier baixo eleva a média.
(b) A média (57,43) é menor que a mediana (65), porque a nota 5 é um outlier baixo que puxa a média para baixo, enquanto a mediana permanece próxima do grosso das notas.
(c) O desvio-padrão é uma medida mais robusta que a mediana diante desse outlier, pois usa todas as observações no cálculo.
(d) Remover o outlier não afetaria a mediana, mas afetaria bastante a média; por isso, a mediana deve sempre substituir a média em qualquer conjunto de dados.
(e) Como a média é menor que a mediana, a distribuição dessas notas é assimétrica à direita.

Bloco 2: Probabilidade

16. (0,5) Um teste A/B mostra a versão A ou a versão B da página a cada usuário, sorteando com a mesma chance e de forma independente. Três usuários acessam a página. Um colega afirma: "o número de usuários que viram a versão A pode ser 0, 1, 2 ou 3; são quatro resultados, então cada um tem probabilidade 1/4". Qual alternativa está correta?

(a) O colega está certo: são quatro resultados possíveis, e a definição clássica dá 1/4 para cada um.
(b) O colega errou ao supor que os quatro resultados são igualmente prováveis. O espaço amostral com pontos equiprováveis são as 8 sequências de três letras (AAA, AAB, ..., BBB), e "exatamente 2 viram A" tem probabilidade 3/8.
(c) O colega errou, porque a probabilidade de cada resultado é 1/3, já que são três usuários.
(d) Não é possível calcular nada sem saber qual versão converte mais.
(e) "Exatamente 2 viram A" tem probabilidade 2/3, a proporção de usuários que viram A.

17. (0,5) Numa loja virtual, 40% dos clientes usam algum cupom de desconto ($P(C) = 0,40$), 25% são clientes novos ($P(N) = 0,25$) e 10% usam cupom **e** são novos ($P(C \cap N) = 0,10$). (a) Qual a probabilidade de um cliente usar cupom **ou** ser novo? (b) Qual a probabilidade de um cliente **não** usar cupom? (c) Os eventos "usar cupom" e "ser cliente novo" são independentes? Justifique pela definição.

18. (0,5) Num sistema de rastreamento de bugs, 60% dos bugs afetam o backend ($P(B) = 0,60$), 30% afetam o frontend ($P(F) = 0,30$) e 20% afetam os dois ao mesmo tempo ($P(B \cap F) = 0,20$). Qual é a probabilidade de um bug afetar o backend **ou** o frontend?

(a) 0,90
(b) 0,70
(c) 1,10
(d) 0,20
(e) 0,50

19. (0,5) Um sistema de suporte registrou os 200 chamados de um mês, cruzando o **canal** de entrada (Chat, E-mail, Telefone) com o fato de o chamado ter sido **resolvido no primeiro contato**:

Resolvido no 1º contato	Chat	E-mail	Telefone	Total
Sim	80	30	40	150
Não	20	20	10	50
Total	100	50	50	200

(a) Qual a probabilidade de um chamado ser resolvido no primeiro contato, **dado** que entrou pelo Chat? (b) Use a regra da probabilidade total para obter a probabilidade de um chamado qualquer ser resolvido no primeiro contato. (c) Um chamado foi resolvido no primeiro contato; qual a probabilidade de que tenha entrado pelo Chat? (Bayes: inverta o condicionamento.)

20. (0,5) Um sistema de detecção de fraude tem **sensibilidade** de 90% (quando a transação é fraudulenta, o alarme dispara em 90% das vezes) e taxa de **falso-positivo** de 5% (quando a transação é legítima, o alarme dispara por engano em 5% das vezes). Apenas 2% das transações são realmente fraudulentas. O alarme acabou de disparar para uma transação. Qual a probabilidade de que ela seja, de fato, fraudulenta?

(a) 90%
(b) 26,9%
(c) 5%
(d) 2%
(e) 1,8%

21. (0,5) Uma equipe tem 10 desenvolvedores. Para um novo projeto, o líder precisa formar uma força-tarefa de 3 pessoas, **sem** distinção de papel entre elas (os três terão a mesma função). De quantas formas diferentes essa força-tarefa pode ser montada?

(a) 720
(b) 1.000
(c) 120
(d) 30
(e) 3.628.800

22. (0,5) Uma equipe de QA tem 12 casos de teste disponíveis. (a) De quantas maneiras ela pode **escolher** 4 casos para revisar, sem se importar com a ordem da revisão? (b) Se, em vez de apenas escolher, ela precisar definir uma **sequência ordenada** de execução para 4 dos 12 casos (a ordem importa), quantas sequências diferentes existem? (c) Explique a relação numérica entre os dois resultados.

23. (0,5) Um lote pequeno de 15 microcontroladores acabou de chegar; sabe-se que 4 deles têm o firmware desatualizado. Um técnico retira 3 ao acaso, **sem reposição** e sem se importar com a ordem, para inspeção. (a) Quantas amostras diferentes de 3 microcontroladores são possíveis? (b) Qual a probabilidade de a amostra conter **exatamente 1** desatualizado? (c) Qual a probabilidade de a amostra conter **pelo menos 1** desatualizado?

24. (0,5) Uma API de pedidos só responde se três serviços funcionarem: autenticação (confiabilidade 0,99), pagamentos (0,97) e catálogo (0,98). Suponha que os três falhem de forma independente. (a) Qual a confiabilidade da API? (b) O serviço de pagamentos ganha uma réplica, com a mesma confiabilidade 0,97, e basta uma das duas cópias funcionar. Qual passa a ser a confiabilidade da API? (c) Se as duas cópias de pagamentos rodarem no mesmo servidor, a conta de (b) continua valendo? Explique.

25. (0,5) De um conjunto de 20 servidores, sabe-se que 6 estão com uma configuração de segurança vulnerável. Uma auditoria sorteia, ao acaso, 4 servidores **sem reposição** para inspeção. Qual a probabilidade de que **exatamente 2** dos 4 sorteados sejam vulneráveis?

(a) 0,265
(b) 0,282
(c) 0,500
(d) 0,003
(e) 0,090

26. (0,5) Uma fila tem 10 tickets de suporte, 4 urgentes e 6 normais. Um atendente pega dois tickets ao acaso, um depois do outro, **sem devolver** o primeiro à fila. (a) Qual a probabilidade de os dois serem urgentes? (b) Qual a probabilidade de o **segundo** ticket ser urgente? (c) Os eventos "o primeiro é urgente" e "o segundo é urgente" são independentes? Justifique.

27. (0,5) Os builds de um projeto rodam em três máquinas: 60% na máquina A, 30% na B e 10% na C. Por problemas de ambiente, a taxa de falha espúria (falha que não vem do código) é de 2% na A, 5% na B e 20% na C. Um build acabou de ter uma falha espúria. Qual a probabilidade de ele ter rodado na máquina C?

(a) 10%
(b) 20%
(c) 42,6%
(d) 4,7%
(e) 2%

28. (0,5) O Nordeste tem 9 das 27 unidades federativas. (a) Sorteando uma unidade federativa ao acaso, qual a probabilidade de ela ser do Nordeste? (b) Agora sorteia-se um **brasileiro** ao acaso, e a pergunta é se ele mora no Nordeste. A resposta é a mesma de (a)? Use `dados/estados.csv` (colunas `Sigla` e `Populacao`; as siglas do Nordeste são MA, PI, CE, RN, PB, PE, AL, SE e BA) para calcular. (c) Explique a diferença entre os dois modelos.

29. (0,5) Num sistema, a probabilidade de falha de disco num dia é 0,10, a de falha de rede é 0,15 e a de as duas falharem no mesmo dia é 0,03. Qual a probabilidade de **nenhuma** das duas falhas ocorrer num dia?

(a) 0,75
(b) 0,765
(c) 0,78
(d) 0,97
(e) 0,22

30. (0,5) Um quiz de fixação tem 8 questões de múltipla escolha, cada uma com 4 alternativas e exatamente uma correta. Um aluno que não estudou responde todas **no chute**, escolhendo uma alternativa ao acaso em cada questão, de forma independente. (a) Quantas folhas de resposta diferentes são possíveis para o quiz inteiro? (b) Qual a probabilidade de o aluno acertar **todas** as 8 questões? (c) Qual a probabilidade de ele acertar **pelo menos 1** questão?