

Lista 1: Prova 1

Bases 3: Estatística · Análise Exploratória e Probabilidade

Nome: _____ Matrícula: _____

Entrega: manuscrita, até 30/10/2026 · 30 questões · 0,5 ponto cada · 15 pontos

Você pode usar Python (Colab) como calculadora, mas as respostas devem ser **escritas à mão**. Nas questões abertas, mostre o raciocínio; nas fechadas, marque a letra e **justifique**.

Bloco 1: Análise Exploratória de Dados

1. (0,5) Um sistema de matrícula universitária registra, entre outros, os campos abaixo para cada aluno:

Campo	Exemplo de valor
Matrícula	202301234
Situação (Ativo ou Trancado)	Ativo
Conceito final do período	B
Créditos cursados no período	12
CR (coeficiente de rendimento)	7,8

Qual alternativa classifica corretamente **todos** os cinco campos, na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário)?

- (a) Matrícula: numérico discreto; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (b) Matrícula: categórico nominal; Situação: ordinal; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.
- (c) Matrícula: categórico nominal; Situação: binário; Conceito: categórico nominal; Créditos: numérico discreto; CR: numérico contínuo.
- (d) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico contínuo; CR: numérico contínuo.
- (e) Matrícula: categórico nominal; Situação: binário; Conceito: ordinal; Créditos: numérico discreto; CR: numérico contínuo.

2. (0,5) Um cadastro de produtos de um e-commerce tem as seguintes variáveis: **SKU** (código do produto, ex.: ELX-0234), **Categoria** (Eletrônicos, Roupas, Alimentos, Livros), **Avaliação do cliente** (de 1 a 5 estrelas, em valores inteiros), **Quantidade em estoque** (unidades inteiras), **Preço unitário** (R\$, com centavos) e **Em promoção** (Sim/Não). Classifique cada uma das seis variáveis na taxonomia numérico (contínuo/discreto) × categórico (nominal/ordinal/binário), justificando cada resposta em uma frase.

3. (0,5) Um sistema de suporte técnico registrou o tempo de atendimento (em minutos) de 10 chamados consecutivos: 4, 5, 5, 6, 6, 7, 7, 8, 9 e 50 (este último passou por escalonamento e ficou muito tempo em fila). Calcule a média, a mediana e a média aparada de 10% desse conjunto. Qual dessas três medidas descreve melhor o tempo “típico” de atendimento, e por quê?

4. (0,5) Uma rede de lojas tem três filiais. A tabela abaixo mostra o valor médio de venda por cliente e o número de transações de cada filial em um mês.

Filial	Valor médio (R\$)	Transações
Centro	40	400
Norte	90	50
Sul	100	50

Qual das alternativas está correta?

- (a) A média simples dos três valores médios (R\$ 76,67) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois trata as três filiais com o mesmo peso.
- (b) A média ponderada pelo número de transações (R\$ 51,00) é a estimativa mais representativa do valor médio de venda por cliente da rede inteira, pois dá mais peso à filial com mais transações.
- (c) A média ponderada será sempre maior que a média simples quando os pesos são diferentes entre os grupos.
- (d) Como a filial Centro tem 400 transações (muito mais que as outras), sua média de R\$ 40 deve ser tratada como um outlier e descartada do cálculo.
- (e) A média ponderada e a média simples medem exatamente a mesma grandeza e, por isso, são sempre iguais.

5. (0,5) Um time de QA registrou o número de erros encontrados por dia, ao longo de 9 dias de testes de um novo sistema: 2, 3, 3, 4, 5, 5, 6, 7, 9. Calcule a variância amostral, o desvio-padrão amostral e o IQR ($q_3 - q_1$, com os quartis pela regra de posição $(n - 1)p + 1$ da seção 1.4) desse conjunto. Em seguida, escreva uma frase interpretando o IQR no contexto do problema.

6. (0,5) As notas de uma avaliação de 5 alunos são: 6, 7, 7, 8, 12. Qual das alternativas apresenta corretamente o desvio-padrão amostral, a variância amostral e a amplitude total (máximo - mínimo) desse conjunto (arredondados a 2 casas quando necessário)?

- (a) desvio-padrão = 5,50; variância = 2,35; amplitude = 6
- (b) desvio-padrão = 2,35; variância = 5,50; amplitude = 6
- (c) desvio-padrão = 2,10; variância = 4,40; amplitude = 6
- (d) desvio-padrão = 2,35; variância = 5,50; amplitude = 12
- (e) desvio-padrão = 4,69; variância = 22,00; amplitude = 6

7. (0,5) As idades (em anos) de 9 clientes cadastrados em uma loja, já em ordem crescente, são: 18, 20, 22, 25, 27, 30, 33, 35, 40. Qual das alternativas apresenta corretamente o primeiro quartil (q_1), o terceiro quartil (q_3) e o IQR desse conjunto, calculados pela regra de posição $(n - 1)p + 1$ da seção 1.4?

- (a) $q_1 = 20$; $q_3 = 35$; IQR = 15
- (b) $q_1 = 22$; $q_3 = 33$; IQR = 11
- (c) $q_1 = 22$; $q_3 = 33$; IQR = 55
- (d) $q_1 = 25$; $q_3 = 30$; IQR = 5
- (e) $q_1 = 18$; $q_3 = 40$; IQR = 22

8. (0,5) O resumo de cinco números de um conjunto de dados é: mínimo = 6, $q_1 = 20$, mediana = 22, $q_3 = 30$, máximo = 68. (a) Calcule o IQR e os limites do bigode pela regra de $1,5 \times \text{IQR}$. (b) O mínimo e o máximo são outliers? (c) Descreva a forma da distribuição: a posição da mediana dentro da caixa e a assimetria provável.

9. (0,5) Um sistema de e-commerce registra o método de pagamento de 200 pedidos: Cartão de crédito (120), Boleto (50), Pix (30). Qual das alternativas está correta?

- (a) A moda dessa variável é “Cartão de crédito”, pois é o método mais frequente (60% dos pedidos).
- (b) A média dos três valores (120, 50, 30) representa o método de pagamento típico dos pedidos.
- (c) Como “Pix” tem a menor contagem, ele deve ser excluído da análise por ser um outlier.
- (d) Cada método de pagamento tem probabilidade de $1/3$ (33,3%), pois há três categorias possíveis.
- (e) A mediana dessa variável categórica é “Boleto”, por ter contagem intermediária.

10. (0,5) Uma operadora de telecomunicações registra os motivos de reclamação de 250 clientes em um mês:

Motivo	Frequência
Cobrança indevida	120
Queda de sinal	80
Atendimento	40
Outro	10

- (a) Calcule a proporção de cada motivo e identifique a moda. (b) Um colega propõe calcular a “média” e a “mediana” do motivo de reclamação. Isso faz sentido? Justifique pelo tipo da variável. (c) Que gráfico é adequado para mostrar essa distribuição, e por quê?
11. (0,5) Um estudo com trabalhadores encontra uma correlação de Pearson $r = -0,82$ entre “horas de sono por noite” e “número de erros cometidos em uma tarefa de digitação”. Qual das alternativas está correta?
- (a) Como r é negativo e próximo de -1 , há uma associação linear forte: mais horas de sono tendem a estar associadas a menos erros. Mas isso, sozinho, não prova que dormir mais causa a redução de erros.
 - (b) $r = -0,82$ significa que dormir mais horas causa, necessariamente, uma redução no número de erros.
 - (c) Como r é negativo, não existe associação alguma entre as duas variáveis.
 - (d) $r = -0,82$ indica uma associação fraca, pois está distante do valor mínimo possível, -2 .
 - (e) Se as horas de sono fossem medidas em minutos em vez de horas, o valor de r mudaria substancialmente.
12. (0,5) Uma pesquisadora relaciona horas semanais de estudo (x) e nota em uma avaliação, de 0 a 100 (y), de 6 estudantes: (2, 50), (4, 55), (6, 65), (8, 70), (10, 80), (12, 100). Calcule o coeficiente de correlação de Pearson entre x e y (mostre as somas intermediárias) e interprete o valor obtido. Essa correlação, por si só, permite concluir que estudar mais **causa** uma nota maior? Justifique.
13. (0,5) Um painel de monitoramento mostra o tempo médio de resposta de três serviços: A com 210 ms, B com 220 ms e C com 240 ms, num gráfico de barras cujo eixo vertical começa em 200 ms. Olhando o gráfico, a barra de C parece ter quatro vezes a altura da barra de A. Qual alternativa está correta?
- (a) O gráfico está correto: C é de fato quatro vezes mais lento que A.
 - (b) O eixo truncado exagera a diferença. As barras medem só o quanto cada serviço passa de 200 ms (10, 20 e 40 ms); o tempo de C é cerca de 1,14 vezes o de A, ou seja, 14% maior.
 - (c) Como os valores são próximos, qualquer gráfico de barras vai esconder a diferença; o certo é não usar gráfico.
 - (d) O problema é o gráfico ser de barras; num gráfico de pizza, a comparação ficaria correta.
 - (e) O eixo truncado só é problema quando os valores são negativos.
14. (0,5) Os tempos de resposta (em ms) de 8 requisições a um serviço foram: 120, 125, 130, 128, 122, 135, 127 e 900 (a última pegou um *timeout* do banco de dados). (a) Calcule a média, o desvio-padrão amostral, a mediana e o desvio absoluto mediano (MAD, com o fator 0,6745 usado na seção 1.4). (b) Recalcule as quatro medidas sem a requisição de 900 ms. (c) Quais medidas mudaram muito e quais quase não mudaram? Explique por quê.
15. (0,5) As notas de 7 alunos em uma prova foram: 60, 62, 65, 68, 70, 72 e 5 (o último aluno entregou a prova em branco, exceto por uma questão). Qual das alternativas está correta?

- (a) A média (57,43) é maior que a mediana (65), porque o outlier baixo eleva a média.
- (b) A média (57,43) é menor que a mediana (65), porque a nota 5 é um outlier baixo que puxa a média para baixo, enquanto a mediana permanece próxima do grosso das notas.
- (c) O desvio-padrão é uma medida mais robusta que a mediana diante desse outlier, pois usa todas as observações no cálculo.
- (d) Remover o outlier não afetaria a mediana, mas afetaria bastante a média; por isso, a mediana deve sempre substituir a média em qualquer conjunto de dados.
- (e) Como a média é menor que a mediana, a distribuição dessas notas é assimétrica à direita.

Bloco 2: Probabilidade

16. (0,5) Um teste A/B mostra a versão A ou a versão B da página a cada usuário, sorteando com a mesma chance e de forma independente. Três usuários acessam a página. Um colega afirma: “o número de usuários que viram a versão A pode ser 0, 1, 2 ou 3; são quatro resultados, então cada um tem probabilidade 1/4”. Qual alternativa está correta?

- (a) O colega está certo: são quatro resultados possíveis, e a definição clássica dá 1/4 para cada um.
- (b) O colega errou ao supor que os quatro resultados são igualmente prováveis. O espaço amostral com pontos equiprováveis são as 8 sequências de três letras (AAA, AAB, ..., BBB), e “exatamente 2 viram A” tem probabilidade 3/8.
- (c) O colega errou, porque a probabilidade de cada resultado é 1/3, já que são três usuários.
- (d) Não é possível calcular nada sem saber qual versão converte mais.
- (e) “Exatamente 2 viram A” tem probabilidade 2/3, a proporção de usuários que viram A.

17. (0,5) Numa loja virtual, 40% dos clientes usam algum cupom de desconto ($P(C) = 0,40$), 25% são clientes novos ($P(N) = 0,25$) e 10% usam cupom e são novos ($P(C \cap N) = 0,10$). (a) Qual a probabilidade de um cliente usar cupom **ou** ser novo? (b) Qual a probabilidade de um cliente **não** usar cupom? (c) Os eventos “usar cupom” e “ser cliente novo” são independentes? Justifique pela definição.

18. (0,5) Num sistema de rastreamento de bugs, 60% dos bugs afetam o backend ($P(B) = 0,60$), 30% afetam o frontend ($P(F) = 0,30$) e 20% afetam os dois ao mesmo tempo ($P(B \cap F) = 0,20$). Qual é a probabilidade de um bug afetar o backend **ou** o frontend?

- (a) 0,90
- (b) 0,70
- (c) 1,10
- (d) 0,20
- (e) 0,50

19. (0,5) Um sistema de suporte registrou os 200 chamados de um mês, cruzando o **canal** de entrada (Chat, E-mail, Telefone) com o fato de o chamado ter sido **resolvido no primeiro contato**:

Resolvido no 1º contato	Chat	E-mail	Telefone	Total
Sim	80	30	40	150
Não	20	20	10	50
Total	100	50	50	200

- (a) Qual a probabilidade de um chamado ser resolvido no primeiro contato, **dado** que entrou pelo Chat? (b) Use a regra da probabilidade total para obter a probabilidade de um chamado qualquer ser resolvido no primeiro contato. (c) Um chamado foi resolvido no primeiro contato; qual a probabilidade de que tenha entrado pelo Chat? (Bayes: inverta o condicionamento.)

20. (0,5) Um sistema de detecção de fraude tem **sensibilidade** de 90% (quando a transação é fraudulenta, o alarme dispara em 90% das vezes) e taxa de **falso-positivo** de 5% (quando a transação é legítima, o alarme dispara por engano em 5% das vezes). Apenas 2% das transações são realmente fraudulentas. O alarme acabou de disparar para uma transação. Qual a probabilidade de que ela seja, de fato, fraudulenta?

- (a) 90%
- (b) 26,9%
- (c) 5%
- (d) 2%
- (e) 1,8%

21. (0,5) Uma equipe tem 10 desenvolvedores. Para um novo projeto, o líder precisa formar uma força-tarefa de 3 pessoas, **sem** distinção de papel entre elas (os três terão a mesma função). De quantas formas diferentes essa força-tarefa pode ser montada?

- (a) 720
- (b) 1.000
- (c) 120
- (d) 30
- (e) 3.628.800

22. (0,5) Uma equipe de QA tem 12 casos de teste disponíveis. (a) De quantas maneiras ela pode **escolher** 4 casos para revisar, sem se importar com a ordem da revisão? (b) Se, em vez de apenas escolher, ela precisar definir uma **sequência ordenada** de execução para 4 dos 12 casos (a ordem importa), quantas sequências diferentes existem? (c) Explique a relação numérica entre os dois resultados.

23. (0,5) Um lote pequeno de 15 microcontroladores acabou de chegar; sabe-se que 4 deles têm o firmware desatualizado. Um técnico retira 3 ao acaso, **sem reposição** e sem se importar com a ordem, para inspeção. (a) Quantas amostras diferentes de 3 microcontroladores são possíveis? (b) Qual a probabilidade de a amostra conter **exatamente 1** desatualizado? (c) Qual a probabilidade de a amostra conter **pelo menos 1** desatualizado?

24. (0,5) Uma API de pedidos só responde se três serviços funcionarem: autenticação (confiabilidade 0,99), pagamentos (0,97) e catálogo (0,98). Suponha que os três falhem de forma independente. (a) Qual a confiabilidade da API? (b) O serviço de pagamentos ganha uma réplica, com a mesma confiabilidade 0,97, e basta uma das duas cópias funcionar. Qual passa a ser a confiabilidade da API? (c) Se as duas cópias de pagamentos rodarem no mesmo servidor, a conta de (b) continua valendo? Explique.

25. (0,5) De um conjunto de 20 servidores, sabe-se que 6 estão com uma configuração de segurança vulnerável. Uma auditoria sorteia, ao acaso, 4 servidores **sem reposição** para inspeção. Qual a probabilidade de que **exatamente 2** dos 4 sorteados sejam vulneráveis?

- (a) 0,265
- (b) 0,282
- (c) 0,500
- (d) 0,003
- (e) 0,090

26. (0,5) Uma fila tem 10 tickets de suporte, 4 urgentes e 6 normais. Um atendente pega dois tickets ao acaso, um depois do outro, **sem devolver** o primeiro à fila. (a) Qual a probabilidade de os dois serem urgentes? (b) Qual a probabilidade de o **segundo** ticket ser urgente? (c) Os eventos “o primeiro é urgente” e “o segundo é urgente” são independentes? Justifique.

27. (0,5) Os builds de um projeto rodam em três máquinas: 60% na máquina A, 30% na B e 10% na C. Por problemas de ambiente, a taxa de falha espúria (falha que não vem do código) é de 2% na A, 5% na B e 20% na C. Um build acabou de ter uma falha espúria. Qual a probabilidade de ele ter rodado na máquina C?

- (a) 10%
- (b) 20%
- (c) 42,6%
- (d) 4,7%
- (e) 2%

28. (0,5) O Nordeste tem 9 das 27 unidades federativas. (a) Sorteando uma unidade federativa ao acaso, qual a probabilidade de ela ser do Nordeste? (b) Agora sorteia-se um **brasileiro** ao acaso, e a pergunta é se ele mora no Nordeste. A resposta é a mesma de (a)? Use `dados/estados.csv` (colunas **Sigla** e **Populacao**; as siglas do Nordeste são MA, PI, CE, RN, PB, PE, AL, SE e BA) para calcular. (c) Explique a diferença entre os dois modelos.

29. (0,5) Num sistema, a probabilidade de falha de disco num dia é 0,10, a de falha de rede é 0,15 e a de as duas falharem no mesmo dia é 0,03. Qual a probabilidade de **nenhuma** das duas falhas ocorrer num dia?

- (a) 0,75
- (b) 0,765
- (c) 0,78
- (d) 0,97
- (e) 0,22

30. (0,5) Um quiz de fixação tem 8 questões de múltipla escolha, cada uma com 4 alternativas e exatamente uma correta. Um aluno que não estudou responde todas **no chute**, escolhendo uma alternativa ao acaso em cada questão, de forma independente. (a) Quantas folhas de resposta diferentes são possíveis para o quiz inteiro? (b) Qual a probabilidade de o aluno acertar **todas** as 8 questões? (c) Qual a probabilidade de ele acertar **pelo menos 1** questão?